

BOI STEM++ Development Programs

โซลูชันพัฒนากำลังคนแห่งอนาคต เพื่อขับเคลื่อน 8 กลุ่มอุตสาหกรรมเป้าหมาย (S-Curve)

IRIS
BrighterBee

AI for High-Value Food Processing & Operations

Batch 2



BOI STEM++ Development Programs

โซลูชันพัฒนากำลังคนแห่งอนาคต เพื่อขับเคลื่อน 8 กลุ่มอุตสาหกรรมเป้าหมาย (S-Curve)

IRIS
BrighterBee

AI for High-Value Food Processing & Operations



Batch 2 / Day 2

สแกนเพื่อใช้คูปองเข้าเรียน

BOI STEM++ Development Programs

โซลูชันพัฒนากำลังคนแห่งอนาคต เพื่อขับเคลื่อน 8 กลุ่มอุตสาหกรรมเป้าหมาย (S-Curve)

IRIS
BrighterBee

AI for High-Value Food Processing & Operations



Batch 2 / Day 2

สแกนเพื่อดาวน์โหลด
เอกสารประกอบการเรียน

IRIS

High-Value Food Industries

AI for High-Value Food Processing & Operations

AI สำหรับการแปรรูปและการดำเนินงานด้านอาหารมูลค่าสูง

รุ่นที่ 2 วันที่ 2



Advanced Data Engineering and Applied Analytics for IT and Developer Teams | Day 1

กฎระเบียบการเข้าเรียนออนไลน์



IRIS BOI-STEAM⁺⁺

กฎ 6 ข้อสำหรับผู้เรียน



1. เปิดกล้องระหว่างเรียน

เพื่อให้ผู้สอนเห็นการมีส่วนร่วม และช่วยให้บรรยากาศการเรียนใกล้เคียงห้องเรียนจริง



2. ปิดไมโครโฟนเมื่อไม่ได้พูด

เพื่อลดเสียงรบกวนระหว่างเรียน



3. เข้าเรียนตรงเวลา

เตรียมอุปกรณ์ให้พร้อมก่อนเริ่มคลาส เช่น อินเทอร์เน็ต หูฟัง สมุดจด หรือไฟล์ประกอบการเรียน



4. มีส่วนร่วมในกิจกรรม

ตอบคำถาม แสดงความคิดเห็น ทำแบบฝึกหัด หรือเข้าร่วมกิจกรรมกลุ่ม



5. ใช้ภาษาสุภาพและเคารพผู้อื่น

ทั้งในการพูด การพิมพ์ในแชต และการแลกเปลี่ยนความคิดเห็นระหว่างเรียน



6. ยกมือก่อนตอบคำถาม

เพื่อให้ผู้สอนจัดลำดับการพูดได้ชัดเจน และลดการพูดแทรกกันระหว่างเรียน



DAY 2

AI Use Case Engineering for High-Value Food Processing

ออกแบบ Use Case ให้พร้อมทดลองจริง: ข้อมูล · การตัดสินใจ ·
Compliance · KPI · ROI

เป้าหมาย: จบวันด้วย **Hero Use Case Proposal**
ที่ใช้ต่อได้ทันที

High-Value Food Industries

ปัญญาประดิษฐ์สำหรับการแปรรูปอาหารมูลค่าสูงและการดำเนินงาน



Advanced Prompt Starters for Use Case Engineering

ปรับ prompt ด้านล่างให้ตรงกับ data, process, ผลิตภัณฑ์ และ compliance context ของบริษัท — อย่า copy-paste โดยไม่ระบุ context ที่เฉพาะเจาะจง

Use Case Framing	<i>I am a [role] in a [product category] plant. The pain point is [specific problem + baseline metric]. We have [data sources with quality description]. Frame this as an AI use case: specify AI function type, required data format, decision point with authority level, expected action + SLA, evidence log fields, and primary KPI with measurement method.</i>
Feasibility Deep-Dive	<i>Evaluate this use case across 5 dimensions: (1) Data readiness [describe data], (2) Integration complexity [list source systems], (3) Interpretability requirement [describe decision maker], (4) Compliance risk [list relevant standards: GMP/HACCP/ISO 22000], (5) Business impact [describe baseline]. Score 1-5 with specific rationale and identify the top 2 risk items to resolve first.</i>
Data Gap Analysis	<i>For this AI use case: [describe use case]. List: (1) required data fields and minimum history length, (2) currently available data with quality assessment, (3) missing data items with severity (critical/important/nice-to-have), (4) pragmatic data collection plan for gaps, (5) minimum viable dataset to start a pilot within 3 months.</i>
KPI Tree Construction	<i>Build a 3-level KPI tree for this use case: [describe]. Level 1: Business outcome (P&L impact). Level 2: Primary lagging KPI with baseline and target. Level 3: Leading indicators that predict the primary KPI (with data source, measurement frequency, and owner). Include a ROI calculation template with key assumptions.</i>
Safety & Compliance Boundary	<i>For this AI use case in [food category]: identify (1) which decisions the AI must NEVER make autonomously (list CCP-related, hold/release, recall, supplier rejection), (2) minimum human approval requirements per decision type, (3) audit trail fields required under [GMP / ISO 22000 / BRC / FDA 21 CFR 11], (4) model validation approach before go-live in a regulated environment.</i>

Technical Glossary: คำศัพท์สำหรับผู้เรียนกลุ่ม Food Technology & Operations

COPQ *Cost of Poor Quality*

ต้นทุนจากคุณภาพไม่ดี: rework, scrap, complaint, claim, hold, delay — ใช้เป็น KPI หลักใน production AI use case

FEFO *First Expired First Out*

หลักการจัดการ inventory ตาม expiry date — AI ช่วย rank shipment priority ตาม FEFO + remaining shelf-life

HACCP CCP *Hazard Analysis & Critical Control Point*

จุดควบคุมวิกฤตที่ AI ห้าม make final decision แทนมนุษย์ ต้องมี human sign-off และ evidence log ตาม §monitoring record

SHAP *SHapley Additive exPlanations*

วิธีอธิบาย AI model output ว่า feature ใดมีผลต่อการ predict มากน้อยแค่ไหน — สำคัญสำหรับ interpretability requirement

MES *Manufacturing Execution System*

ระบบควบคุมการผลิตที่บันทึก batch record, process parameter, downtime — เป็น data source หลักของ production AI

LIMS *Laboratory Information Management System*

ระบบจัดการผลการทดสอบในห้องปฏิบัติการ — data source หลักของ QA/QC AI use case

GDP *Good Distribution Practice*

หลักเกณฑ์การกระจายสินค้าที่ดี (WHO/EU) — กำหนด temperature control, documentation สำหรับ cold-chain AI

PDPA *Personal Data Protection Act*

พ.ร.บ.คุ้มครองข้อมูลส่วนบุคคล (ไทย) — ต้องตรวจสอบว่า training data ของ AI ไม่มี PII โดยไม่ได้รับความยินยอม

DoE-AI *Design of Experiments + AI*

การใช้ Bayesian Optimization หรือ Gaussian Process แทน one-factor-at-a-time เพื่อลดจำนวน trial ใน R&D

Human-in-Loop *Human-in-the-Loop Checkpoint*

จุดในกระบวนการที่มนุษย์ต้องตรวจสอบและอนุมัติก่อน action — กฎ: ทุก decision ที่กระทบ food safety ต้องมี human gate

Pilot Scope *Minimum Viable Pilot*

การทดสอบ use case ใน scope เล็กที่สุดที่ยังวัดผลได้จริง: 1 line, 1 shift, 1 site, 3 เดือน — ก่อน scale

Arrhenius Model *Shelf-life Kinetics*

สมการทำนาย shelf-life จาก temperature history: $k = A \cdot e^{(-E_a/RT)}$ — ใช้ใน cold-chain AI และ accelerated shelf-life testing

Workshop Architecture & Learning Outcomes

9:00–9:15	Bridge Day 1	ทบทวน Problem Statement & KPI Draft จาก Day 1 · วิเคราะห์ gap ระหว่าง pain point และ data ที่มี	11:30–13:30	Lab 2	Data-to-Decision Map: เชื่อม trigger → input → model logic → decision → action → evidence log ตาม GMP
9:15–9:55	Theory 1	Anatomy of a Production-Ready AI Use Case: 7 องค์ประกอบ + Decision Typology + Data Architecture	13:30–14:30	Lab 3	Feasibility & Risk Scoring: ประเมิน 5 มิติ + compliance taxonomy + integration complexity mapping
9:55–10:30	Theory 2	Four Use Case Domains: Production · QA/QC · Distribution · Cost & Margin พร้อม model type mapping	14:30–15:30	Lab 4	Hero Use Case Canvas: เลือก 1 use case + เขียน proposal ระดับ pilot-ready ที่ผ่าน safety gate
10:30–11:30	Lab 1	Use Case Ideation: เลือก 3-5 use cases จาก 8 อุตสาหกรรม พร้อม annotate data source และ decision type	15:30–16:00	Lab 5	KPI Tree + ROI Hypothesis: เชื่อม business outcome → primary KPI → leading indicator → data owner

7 องค์ประกอบของ AI Use Case ที่ Deploy ได้จริง

01

Pain Point & Business Driver

ระบุ process failure mode ที่วัดได้: yield loss %, deviation frequency, COPQ \$/month, complaint ppm — ไม่ใช่ปัญหากว้าง ๆ

02

Data Input & Signal Quality

ระบุ data type (sensor / vision / lab / ERP), sampling rate, missing rate %, time alignment และ data governance owner

03

Analytical Logic & Model Type

เลือก function: Classify · Predict (regression) · Rank · Recommend · Detect anomaly · Generate draft — แต่ละ function ต้องการ labeled data ต่างกัน

04

Decision Point & Authority Matrix

ระบุ decision type (hold/release · rework · PM schedule · route change · supplier action), threshold ที่ trigger action และ human authority level ตาม SOP

05

Action & Response Time

กำหนด action หลัง AI output: quarantine lot · adjust process parameter · notify supervisor · escalate to QA manager — พร้อม SLA ของแต่ละ action

06

Evidence Log & Audit Trail

บันทึก timestamp · lot/batch · model version · confidence score · human decision · corrective action ตาม GMP และ ISO 22000 §8.9

07

KPI Metric & Baseline

กำหนด primary KPI (FPY, COPQ, deviation rate) พร้อม baseline ปัจจุบัน target ที่ measurable และ measurement frequency

⚠ Use case ที่ขาดองค์ประกอบใดองค์ประกอบหนึ่งมักกลายเป็น proof-of-concept ที่ deploy ไม่ได้ในสภาพแวดล้อมการผลิตจริง

Decision Typology: เลือก AI Function ให้ตรงกับ Decision ที่ต้องการ

CLASSIFY

สิ่งนี้คือประเภทใด?

Model: CNN / XGBoost / Random Forest

Food: Vision inspection: บกพร่อง ชั้นวัตถุดิบ สีผิด ฝาชำรุด

Data req: Labeled images หรือ tabular records (1,000+ samples/class)

PREDICT

จะเกิดอะไรขึ้น / ค่าจะเท่าไร?

Model: LSTM / XGBoost / ARIMA / Prophet

Food: Yield loss, shelf-life remaining, fermentation alcohol %, energy demand

Data req: Time-series sensor data หรือ batch records ≥ 3 เดือน

RANK / SCORE

อะไรเสี่ยง/สำคัญที่สุด?

Model: Scoring model / Weighted index / LightGBM

Food: Supplier quality risk, lot mycotoxin risk, shipment excursion priority

Data req: Multi-attribute historical records พร้อม outcome label

RECOMMEND

ควรทำอะไร / ปรับอะไร?

Model: Optimization solver / RL / Bayesian optimization

Food: Formulation within nutrient & cost constraint, process window, routing

Data req: Recipe/parameter space + constraint rules + outcome feedback

DETECT ANOMALY

มีสิ่งผิดปกติหรือไม่?

Model: Isolation Forest / Autoencoder / SPC control chart

Food: Sensor drift, Brix deviation, CIP performance degradation, fill-level anomaly

Data req: Normal-state baseline (unsupervised) หรือ labeled anomaly events

GENERATE DRAFT

สร้างร่างข้อความ/รายงานจากข้อมูล?

Model: LLM (GPT-4 class) with structured prompt + retrieval

Food: HACCP deviation report draft, supplier NCA letter, specification document

Data req: Template + structured data input; ต้องมี human review ก่อน release เสมอ

Rapid Development with Claude AI

The Georgia Tech Hackathon

ถอดบทเรียนจากการแข่งขันสร้างแอปพลิเคชันสุขภาพภายในเวลาเพียง 3 ชั่วโมง โดยใช้ AI เป็นผู้ช่วยหลัก

-  **Speed & Efficiency:** การใช้ Claude AI ช่วยลดเวลาการเขียนโค้ดพื้นฐาน (Boilerplate) ทำให้นักศึกษาโฟกัสที่ไอเดียได้มากขึ้น
-  **Human-AI Partnership:** AI ไม่ได้มาแทนคน แต่เป็น "Co-pilot" ที่ต้องอาศัยตรรกะและการตัดสินใจของมนุษย์ในการควบคุม
-  **Creative Outcomes:** ทีมผู้ชนะสร้างแอปติดตามมื้ออาหารที่ใช้ระบบ Gamification เพื่อเปลี่ยนพฤติกรรมสุขภาพให้สนุกขึ้น



<https://youtu.be/l3NGtWZTGGg>

ภาพรวม Day 2: จาก Pain Point สู่ Use Case ที่ทำได้จริง

ไม่ได้เริ่มจากโมเดล แต่เริ่มจากการตัดสินใจที่องค์กรอยากปรับปรุง

หลังจาก Day 1 เรามี Problem Statement และ KPI Draft แล้ว Day 2 จะเปลี่ยนสิ่งนั้นให้เป็นแผน AI Use Case ที่ชัดเจนสำหรับ Pilot

แยก “ปัญหาในการทำงาน” ออกจาก “ไอเดียเทคโนโลยี” เพื่อให้ไม่เริ่มผิดจุด

กำหนดข้อมูลที่ต้องใช้ รวมถึงคุณภาพข้อมูล ความถี่ และความเชื่อมโยงกับ Lot/Batch

เลือก AI Function ที่เหมาะกับงาน เช่น Classify, Predict, Rank, Recommend, Detect anomaly หรือ Generate draft

วางขอบเขตความปลอดภัยอาหารและจุดอนุมัติของมนุษย์ก่อนทดลองจริง

ตัวอย่างใช้งานจริง

ตัวอย่างเป้าหมายท้ายวัน: “ลด defect ผาขวดในสายบรรจุเครื่องดื่ม โดยใช้ภาพจากกล้อง + reject log เพื่อช่วย QA คัดกรองความเสี่ยง และวัดผลด้วย complaint ppm / false reject rate / rework cost”

Good use case = ปัญหาวัดได้ + ข้อมูลใช้ได้ + คนตัดสินใจชัด + KPI ชัด



Food value chain + AI decision points

Workshop Flow: 6 ชั่วโมงของ Day 2

เรียงจากหลักคิด → ตัวอย่าง → ลงมือทำ → เลือก Hero Use Case

โครงสร้างวันนี้แบ่งเป็นช่วงสั้น ๆ เพื่อให้ผู้เรียนค่อย ๆ เพิ่มความละเอียดของ **Use Case** ทีละขั้น

ช่วงต้น: ทบทวน Problem Statement และเรียนโครงสร้าง Use Case ที่ Deploy ได้จริง

ช่วงกลาง: เรียน AI Function และ 4 Domains ของอุตสาหกรรมอาหาร พร้อม Use Case Bank

ช่วงปฏิบัติ: Ideation, Data-to-Decision Map, Feasibility Scoring และ Hero Use Case Canvas

ช่วงท้าย: สร้าง KPI Tree + ROI Hypothesis แล้วเตรียมนำเสนอ Use Case ของทีม

ตัวอย่างใช้งานจริง

คำแนะนำ: ทุก Lab ควรถามว่า “ข้อมูลมาจากไหน”, “ใครต้องอนุมัติ”, “ถ้า AI ผิดจะเกิดอะไรขึ้น”, “จะรู้ได้อย่างไรว่าได้ผลจริง”

Flow ของวันถูกออกแบบให้ลดความฟุ้งและเพิ่มความพร้อมในการทดลองจริง

Bridge	Part 1:	Part 2:	Part 3:	Part 4:
Day 1	Theory Use Case	AI Function + Domains	Lab 1–3 เลือกและประเมิน	Lab 4–5 Hero + KPI

Part 3

Lab 1–3

เลือกและประเมิน



Lab 1: Use Case Ideation Canvas

เปิดตัวเลือก 3–5 Use Cases ก่อนเลือก Hero

Lab นี้ให้ทีมคิดหลายตัวเลือกโดยใช้ข้อมูลจากงานจริงหรือ **Use Case Bank** แล้ว **annotate** ให้ครบ ไม่ใช่เลือกจากข้อที่ฟังดูดี

Use Case Name: ตั้งชื่อให้เห็น domain และ decision เช่น “Cold-chain risk scoring for DC release review”

Pain Point: ระบุ metric และ baseline เช่น complaint ppm, downtime hr, COPQ THB/year

Data Available: ระบุระบบจริง เช่น MES, LIMS, ERP, WMS, camera, IoT logger พร้อมข้อจำกัด

AI Function: เลือก classify/predict/rank/recommend/detect/generate และอธิบายเหตุผล

Decision Owner: ระบุตำแหน่งจริงที่ต้องใช้ output และอนุมัติ action

Impact Estimate: ประมาณผลลัพธ์เชิง KPI หรือ THB/year แบบมี caveat

ตัวอย่างใช้งานจริง

เวลา 45–60 นาที: 25 นาทีเติม canvas, 15 นาทีเลือก Top 2, 10 นาทีเตรียมเหตุผล, 10 นาที present สั้น ๆ

Lab 1 ต้องทำให้เห็นตัวเลือกและข้อเท็จจริง ไม่ใช่แค่ brainstorming



Use case ideation workshop

Lab 1 Example: Cap Defect Reduction

ตัวอย่างการกรอกที่ละเอียดพอให้ทีมอื่นเข้าใจ

ตัวอย่างนี้แสดงการเปลี่ยนปัญหา “ฝาขวดมี defect” ให้เป็น **use case** ที่มีข้อมูล **owner** และ **impact** ชัดเจน

Use Case: Vision Inspection for Cap Defect Reduction ในสายบรรจุเครื่องดื่ม Line 2

Pain Point: complaint จากฝาชำรุด 110 ppm และ rework cost ประมาณ 850,000 THB/year

Data: ภาพจากกล้อง inspection, reject log, shift record, cap torque, complaint record, QA confirmation label

AI Function: Classify defect type + confidence score; rank case ที่ confidence ต่ำให้ QA review

Decision Owner: QA Supervisor ตรวจ critical case; Line Supervisor จัดการ rework/quarantine

Impact: ลด complaint 30%, ลด rework 20%, false reject ไม่เกิน baseline + 10%

ตัวอย่างใช้งานจริง

ข้อควรเติมใน canvas: lighting condition, camera calibration, defect taxonomy, number of labeled images per defect class และ SOP สำหรับ case ที่ AI/คนไม่ตรงกัน

ตัวอย่างที่ดีต้องมี **baseline, data source, human gate** และ **KPI** พร้อมกัน



Sample Lab 1: cap defect use case



Lab 1: Use Case Ideation Canvas

ทีมเลือก 3–5 use cases จาก Use Case Bank หรือจากงานจริง แล้ว annotate ข้อมูลด้านล่างให้ครบ — ห้ามเลือกเพราะ "ข้อดูดี" ให้เลือกเพราะมีข้อมูลและมี decision owner ชัดเจน

#	Use Case Name	Pain Point (วัดได้)	ข้อมูลที่มีอยู่จริง	AI Function (classify/predict/etc.)	Decision Owner	Impact ประมาณ
1						
2						
3						
4						
5						
🕒 30 นาที: เขียน canvas ทุก row ให้ครบก่อน 15 นาที: ทีมอภิปรายเลือก top 2 15 นาที: present top 2 พร้อมเหตุผล data & decision						



Lab 2: Data-to-Decision Map

ลากเส้นจาก Trigger ไปจนถึง Evidence Log

Lab นี้ใช้ตรวจว่า **Use Case** ไม่ได้หยุดที่โมเดล แต่เดินครบวงจรจนเกิด **action** และหลักฐานตาม **SOP**

Trigger: เหตุการณ์ใดเริ่ม workflow เช่น batch start, threshold breach, truck arrival, scheduled review

Data Inputs: ข้อมูลมาจากไหน ความถี่เท่าไร คุณภาพอย่างไร และถ้าหายจะอย่างไร

Feature / Model Logic: AI ใช้สัญญาณใด สร้าง output รูปแบบใด และมี confidence metric หรือไม่

Decision Point: ใครตัดสินใจ threshold คืออะไร และมี approval กี่ระดับ

Action & SLA: หลังตัดสินใจแล้วทำอะไร ใครรับผิดชอบ และต้องทำภายในเวลาเท่าไร

Evidence Log: บันทึกอะไรบ้างเพื่อ audit และเรียนรู้หลัง action

ตัวอย่างใช้งานจริง

ถ้าเขียน map แล้วพบว่า “AI แฉงเตือน แต่ไม่รู้ว่าจะใครต้องทำอะไร” แสดงว่า use case ยังไม่พร้อมเป็น pilot

Data-to-Decision Map คือสะพานจากโมเดลสู่การทำงานจริง



Lab 2 Example: Cold-Chain Excursion Risk Map

ตัวอย่าง map สำหรับสินค้าที่ต้องควบคุมอุณหภูมิ

กรณีนี้ AI ไม่ได้ตัดสินใจปล่อยหรือ **hold** เอง แต่ช่วยจัดลำดับ **shipment** ที่ควรตรวจและเตรียม **evidence package** ให้ QA

Trigger: รถขนส่งถึง Distribution Center และ upload temperature logger data

Data Inputs: temp ทุก 15 นาที, route, dwell time, door-open, product TTI, lot ID, customer shelf-life requirement

Model Output: excursion pattern + risk score + predicted shelf-life remaining + confidence

Decision Point: Logistics Supervisor ตรวจ score; QA review ถ้า score > threshold หรือ shelf-life remaining ต่ำ

Action & SLA: hold for inspection ภายใน 30 นาที หรือ release ตาม SOP หลัง QA sign-off

Evidence Log: temp graph, route ID, model version, threshold, human decision, corrective action, final disposition

ตัวอย่างใช้งานจริง

KPI ที่ใช้วัด: excursion decision lead time, claim rate, shelf-life remaining at delivery, false alarm rate และ number of shipments escalated to QA

ตัวอย่างนี้แสดงว่า AI ช่วยจัดลำดับและเตรียมหลักฐาน ไม่ใช่แทน QA





Lab 2: Data-to-Decision Map

เลือก 2 use cases ที่สนใจที่สุด แล้วเขียน data pipeline ตั้งแต่ trigger จนถึง evidence log — ถ้า action ไม่ชัด หรือไม่มี human checkpoint แปลว่า use case ยังไม่สมบูรณ์

Trigger	เหตุการณ์ใดทำให้ workflow เริ่มทำงาน? (batch start / threshold breach / scheduled / on-demand)
Data Inputs	ระบุ data type, source system, sampling frequency, data quality assumption และ missing data plan
Feature Engineering	ต้องแปลง raw data เป็น features อะไร? (lag features, rolling stats, ratio, encoded category)
Model Logic	AI ต้องทำอะไร: classify / predict / rank / recommend / detect anomaly / generate — ระบุ output format และ confidence metric
Decision Point	ใครต้องตัดสินใจ? ระดับ threshold ที่ trigger action คืออะไร? มีกี่ approval tier?
Action & SLA	หลังตัดสินใจแล้วทำอะไรต่อ? ใครรับผิดชอบ? ต้องทำภายในเวลาที่ช้าโมงตาม SOP?
Evidence Log	บันทึก: timestamp, lot/batch, model version, confidence score, human decision, corrective action ตาม GMP audit trail



USE CASE A	USE CASE B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B

Lab 3: Feasibility & Risk Scoring Matrix

ให้คะแนน Top 2–3 Use Cases เพื่อเลือก Hero

Lab นี้ให้ทีมถกกันด้วยเหตุผล ไม่ใช่รวมคะแนนแบบอัตโนมัติ เพราะแต่ละคะแนนมีนัยต่อการทำงานจริง

ให้คะแนน 1–5 ใน 5 มิติ: data, integration, interpretability, compliance control, business impact

ต้องเขียน rationale ทุกคะแนน เช่น “Data = 3 เพราะมี 6 เดือน แต่ label ยังไม่สม่ำเสมอ”

ระบุ top 2 risk items ที่ต้องแก้ก่อน pilot เช่น label quality, API access, SOP approval, QA workload

อย่าดูแค่ผลรวม ให้ดูเงื่อนไขขั้นต่ำ: Impact ≥ 4 และ Compliance control ≥ 3

สรุปว่า use case ใดเป็น Hero, use case ใดเป็น roadmap และ use case ใดควรพักไว้ก่อน

ตัวอย่างใช้งานจริง

ตัวอย่าง score: Cap defect vision = Data 3, Integration 4, Interpretability 3, Compliance 4, Impact 4 → เหมาะเป็น Hero ถ้า label defect พร้อมภายใน 4 สัปดาห์

คะแนนที่ดีต้องมีเหตุผลและแผนลดความเสี่ยงประกอบ

Data



Integration



Explain



Compliance



Impact





Lab 3: Feasibility & Risk Scoring Matrix

ให้คะแนน 1-5 (1 = ต่ำ/ยังไม่พร้อม / เสี่ยงสูง, 5 = สูง/พร้อม/ควบคุมได้ดี) — คูณผลรวม + อภิปรายเหตุผล อย่าดูแค่ตัวเลข

Use Case Name	Data Readiness	Integration Readiness	Interpretability & Explainability	Compliance Risk Control	Business Impact	Rationale สั้น
Scoring guide Compliance Risk Control: 1 = กระทบ CCP ไม่มี safeguard · 3 = มี boundary ชัด มี human sign-off · 5 = ไม่กระทบ critical control, audit-ready Hero threshold: Impact ≥ 4 + Compliance ≥ 3						

PM Break

กลับมาเรียนพร้อมกันอีกครั้ง **14.45**

น.



Part 4

Lab 4–5

Hero + KPI



Lab 4–5: Hero Use Case Canvas + KPI Tree + ROI

รวมทุกอย่างให้เป็น proposal ที่พร้อมนำเสนอ

ขั้นสุดท้ายให้เลือก **use case** เดียวและเขียนให้ครบระดับ **pilot-ready** พร้อม **KPI** และสมมติฐาน **ROI** ที่ตรวจสอบได้

Hero Canvas: ชื่อ use case, business problem, baseline, decision owner, data input, AI output, human checkpoint

Compliance Boundary: ระบุ AI ห้ามทำอะไรเอง และต้องมี approval ที่จุดใด


Pilot Scope: 1 line/1 site/1 route/1 product family, ระยะเวลา 3 เดือน, success/failure criteria

KPI Tree: business outcome → primary KPI → leading indicators → data source → owner/frequency

ROI Hypothesis: baseline, target, value THB/year, implementation cost, assumption และ caveat

ตัวอย่างใช้งานจริง

Closing prompt สำหรับทีม: “ใน 90 วันแรก เราจะพิสูจน์อะไร ใช้ข้อมูลจากไหน ใครต้องเปลี่ยนพฤติกรรม และถ้า KPI ไม่ดีขึ้น เราจะรู้ได้อย่างไรว่าเป็นเพราะข้อมูล โมเดล หรือ workflow?”



จบ Day 2 ด้วย proposal ที่ใช้คุยต่อเรื่อง Pilot ได้ทันที

Closing: จาก Use Case สู่ Pilot Roadmap

สิ่งสำคัญไม่ใช่การมีไอเดีย AI มากที่สุด แต่คือการเลือก Use Case ที่วัดผลและควบคุมความเสี่ยงได้ดีที่สุด

ข้อความสรุปสำหรับผู้เรียน

AI Project ที่ดีเริ่มจาก measurable decision ไม่ใช่เริ่มจาก model name

Use Case ที่พร้อม Pilot ต้องตอบ data, decision, owner, compliance boundary และ KPI ได้ครบ

ความปลอดภัยอาหารและ human sign-off ต้องถูกออกแบบตั้งแต่ต้น ไม่ใช่เติมภายหลัง

Pilot ที่เล็กพอและวัดผลชัดเจน มีโอกาส scale มากกว่าโครงการใหญ่ที่ไม่มี baseline

Hero Use Case วันนี้ควรกลายเป็น action plan 3 เดือน พร้อม owner และ success criteria



Use Case
Proposal

Data Plan

Pilot
Execution

KPI Review

Scale / Stop
Decision

Good AI projects do not start from models. They start from measurable decisions.

Feasibility Filter: ประเมิน Use Case ก่อนลงแรงพัฒนา

Data Readiness

- มี historical data ≥ 6 เดือน ครอบคลุม process variation ที่สนใจหรือไม่
- Missing rate $< 15\%$ หรือมี imputation strategy ที่ QA ยอมรับ
- Data ถูก timestamp และ lot-linked ตาม batch record ที่ traceable ใหม่
- มี data governance: owner, access control, retention policy ชัดหรือไม่

Integration Readiness

- ต่อเข้า MES / ERP / LIMS / WMS / TMS ผ่าน API หรือ data lake ได้ไหม
- Latency requirement: real-time (< 1 s) vs near-real-time (< 5 min) vs batch (daily)
- IT security ยอมรับ cloud inference หรือต้องการ on-premise deployment
- มี sandbox/staging environment สำหรับทดสอบ integration ก่อน go-live

Interpretability

- Operators และ QA สามารถเข้าใจเหตุผล (feature importance / SHAP values) หรือไม่
- Model output ต้องอธิบายได้ใน language ของ user (ไม่ใช่แค่ score)
- สามารถ override AI recommendation ได้เสมอ และมี log ของการ override
- มี human-readable confidence threshold ที่ define action level

Compliance Risk Control

- AI decision กระทบ HACCP CCP / OPRP หรือ GMP critical process ใหม่
- มี documented safety boundary ว่า AI ห้าม make final decision ด้าน release/recall
- Audit trail บันทึก model version, input, output, human decision ตาม §21 CFR 11 หรือ ISO 22000
- Regulatory authority (อย. / FDA / EFSA) ยอมรับ AI-assisted decision ใน context นี้หรือไม่

Business Impact

- ประมาณ financial impact ได้: ลด COPQ $\times \% = y$ THB/year; baseline คืออะไร
- มี sponsor ระดับ manager ขึ้นไปที่ commit ทรัพยากรและ process change
- Time-to-value: คาดว่า pilot result เห็นภายใน 3–6 เดือนได้หรือไม่
- หากระบบล้มเหลว process fallback ยังทำงานได้โดยไม่กระทบ food safety

Hero Use Case ต้องมี Business Impact ≥ 4 และ Compliance Risk Control ≥ 3 ก่อนเลือกเป็น hero — ถ้า Impact สูงแต่ Data Readiness = 1 ให้จัดเป็น Roadmap item แทน



Lab 4: Hero Use Case Canvas — Pilot-Ready Proposal

กรอกให้ครบทุกช่อง ถ้ากรอกไม่ได้ แปลว่ายังต้องลดขอบเขตหรือเลือก use case ใหม่ — ผ่านเกณฑ์เมื่อตอบ [data · decision · owner · compliance boundary · KPI] ได้ครบ

Hero Use Case Name ระบุชื่อ use case พร้อม domain (Production / QA / Distribution / Cost)	Human-in-Loop Checkpoint ระบุจุดที่มนุษย์ต้องตรวจสอบและอนุมัติก่อน action — AI ห้ามทำแทนใน critical decision
Business Problem & Baseline ปัญหาที่เกิดขึ้นจริง: ระบุ baseline metric ปัจจุบัน เช่น FPY = 87%, COPQ = 2.3M THB/yr	Compliance & Safety Boundary ระบุ GMP / HACCP / ISO 22000 clause ที่เกี่ยวข้อง + decision ที่ AI ห้ามทำโดยอัตโนมัติ
Decision Owner & Authority Level ระบุตำแหน่ง, ระดับ approval (supervisor / QA manager / plant director), SOP reference	Required Systems & Integration ระบุ MES / ERP / LIMS / SCADA / WMS ที่ต้องเชื่อมต่อ + API หรือ data lake approach
Data Inputs & Quality Assessment ระบุ data type, source, sampling rate, missing rate % และ action if data unavailable	Expected Action & SLA หลัง AI output → ทำอะไร → ใครรับผิดชอบ → ต้องทำภายในกี่ชั่วโมง ตาม SOP
AI Output Format & Confidence Metric AI ส่งออกมาในรูปแบบ: score / class + confidence % / recommendation list / anomaly flag	Pilot Scope & Success Criteria ทดสอบที่ไหน (1 line / 1 site), กี่เดือน, นับ success เมื่อ KPI target ผ่าน threshold ใด





Lab 5: KPI Tree & ROI Hypothesis

KPI Tree: เชื่อม Business Outcome → Primary KPI → Leading Indicator → Data Source → Owner

Business Outcome	Primary KPI (Lagging)	Leading Indicator (Early Signal)	Data Source & Measurement	Owner & Frequency

ROI Hypothesis — ระบุ financial impact ของ hero use case พร้อม assumption ที่ชัดเจน

Impact Category	Baseline (ปัจจุบัน)	Target (หลัง deploy)	Business Value THB/yr (ประมาณ)	Key Assumption & Caveat
ลดของเสีย / Rework / Scrap				
ลด Complaint / Claim / Recall cost				
ลด Downtime / Energy / Utility				
ลดเวลาตรวจสอบ / Hold-to-Release lead time				

DAY 2 OUTPUT

เกณฑ์ผ่าน Day 2 & Deliverables

01

AI Use Case Proposal (Structured)

ระบุครบ: pain point + baseline metric · data input + quality · AI function + model type · decision point + authority · compliance boundary · expected action + SLA

02

Hero Use Case Selection Rationale

อธิบายเหตุผลที่เลือก use case นี้แทนตัวเลือกอื่น: feasibility score comparison · data readiness assessment · business impact vs risk trade-off

03

KPI Tree Draft + ROI Hypothesis

เชื่อม business outcome → primary KPI → leading indicator → data source → owner · พร้อม ROI estimate พร้อม assumption และ caveat ที่ชัดเจน

✓ เกณฑ์ผ่าน: ทีมตอบได้ว่า **use case** ใช้ข้อมูลอะไร · ตัดสินใจเรื่องอะไร · ใครอนุมัติ
· **compliance boundary** ที่ชัด · วัดผลด้วย **KPI** ไດ · **pilot scope** เล็กสุดคืออะไร



Next Step

วิชาที่ 2 AI for High-Value Food Processing & Operations (รุ่น 2)

- Workshop Day 1 Thu, 14 May
- Workshop Day 2 Tue, 19 May
- Workshop Day 3 Tue, 26 May
- Coaching Sessions Fri, 5 Jun
- Project Pitching Sun, 12 Jul

○ Thank You