



Automation Tool : Codex

IRIS Activity

เกณฑ์ผ่าน Day 2 & Deliverables

01

AI Use Case Proposal (Structured)

ระบุครบ: pain point + baseline metric · data input + quality · AI function + model type · decision point + authority · compliance boundary · expected action + SLA

02

Hero Use Case Selection Rationale

อธิบายเหตุผลที่เลือก use case นี้แทนตัวเลือกอื่น: feasibility score comparison · data readiness assessment · business impact vs risk trade-off

03

KPI Tree Draft + ROI Hypothesis

เชื่อม business outcome → primary KPI → leading indicator → data source → owner · พร้อม ROI estimate พร้อม assumption และ caveat ที่ชัดเจน

✓ เกณฑ์ผ่าน: ทีมตอบได้ว่า use case ใช้ข้อมูลอะไร · ตัดสินใจเรื่องอะไร · ใครอนุมัติ · compliance boundary ที่ชัด · วัดผลด้วย KPI ไດ · pilot scope เล็กสุดคืออะไร



IRIS : LABs

IRIS Activity



IRIS : LAB₁

IRIS Activity

Lab 1: Use Case Ideation Canvas

Lab นี้ให้ทีมคิดหลายตัวเลือกโดยใช้ข้อมูลจากงานจริงหรือ **Use Case Bank (See Appendix)** แล้ว **annotate** ให้ครบ ไม่ใช่เลือกจากข้อที่ฟังดูดี

Use Case Name: ตั้งชื่อให้เห็น domain และ decision เช่น “Cold-chain risk scoring for DC release review”

Pain Point: ระบุ metric และ baseline เช่น complaint ppm, downtime hr, COPQ THB/year

Data Available: ระบุระบบจริง เช่น MES, LIMS, ERP, WMS, camera, IoT logger พร้อมข้อจำกัด

AI Function: เลือก classify/predict/rank/recommend/detect/generate และอธิบายเหตุผล

Decision Owner: ระบุตำแหน่งจริงที่ต้องใช้ output และอนุมัติ action

Impact Estimate: ประมาณผลลัพธ์เชิง KPI หรือ THB/year แบบมี caveat



Lab 1 ต้องทำให้เห็นตัวเลือกและข้อเท็จจริง ไม่ใช่แค่ brainstorming

Lab 1 Example: Cap Defect Reduction

ตัวอย่างการกรอกที่ละเอียดพอให้ทีมอื่นเข้าใจ

ตัวอย่างนี้แสดงการเปลี่ยนปัญหา “ฝาขวดมี defect” ให้เป็น use case ที่มีข้อมูล owner และ impact ชัดเจน

Use Case: Vision Inspection for Cap Defect Reduction ในสายบรรจุเครื่องดื่ม Line 2

Pain Point: complaint จากฝาชำรุด 110 ppm และ rework cost ประมาณ 850,000 THB/year

Data: ภาพจากกล้อง inspection, reject log, shift record, cap torque, complaint record, QA confirmation label

AI Function: Classify defect type + confidence score; rank case ที่ confidence ต่ำให้ QA review

Decision Owner: QA Supervisor ตรวจ critical case; Line Supervisor จัดการ rework/quarantine

Impact: ลด complaint 30%, ลด rework 20%, false reject ไม่เกิน baseline + 10%

ตัวอย่างใช้งานจริง

ข้อควรเติมใน canvas: lighting condition, camera calibration, defect taxonomy, number of labeled images per defect class และ SOP สำหรับ case ที่ AI/คนไม่ตรงกัน

ตัวอย่างที่ดีต้องมี baseline, data source, human gate และ KPI พร้อมกัน



Lab 1: Use Case Ideation Canvas

ทิมเลือก 3–5 use cases จาก Use Case Bank หรือจากงานจริง แล้ว annotate ข้อมูลด้านล่างให้ครบ — ห้ามเลือกเพราะ "ข้อคิด" ให้เลือกเพราะมีข้อมูลและมี decision owner ชัดเจน

#	Use Case Name	Pain Point (วัดได้)	ข้อมูลที่มีอยู่จริง	AI Function (classify/predict/etc.)	Decision Owner	Impact ประเมิน
1	Work with Codex (Optional): - นำ 1 Use Case ใน Use Case Bank (หรือใช้ Use Case ของตนเอง) เป็นข้อมูลเบื้องต้น - Prompt ให้ Codex ทำ Excel ให้ โดยมี Column ตามที่โจทย์ต้องการ - เขียน Prompt ให้ชัดเจน (Role, ICIO, Check Condition) (ตัวอย่าง - สามารถนำไปปรับปรุงหรือเขียนของตนเองใหม่ได้) - Role = Use Case Ideation Canvas Builder + กฎทั่วไป เช่น ห้ามเดาโดยไม่ได้รับอนุญาต - Instruction = วิเคราะห์ Use Case ใส่ใน Canvas - Context = ใช้สำหรับเป็น AI Use Case Proposal - Input = (ข้อมูลจาก Use Case Bank หรือของเราเอง) - Output = ตาราง Excel เป็น File (.xlsx) ประกอบด้วย Column : ..., ความยาวแต่ละ Cell ไม่เกิน ..., ภาษาไทย - Check Condition / Constraint = - หากข้อมูลไม่เพียงพอ หรือไม่สามารถกรอก Column ใดได้ ให้ถามกลับเสมอ เพื่อสอบถามไต่ถามจากคนเพิ่มเติม - สามารถแนะนำการกรอกได้ แต่ต้องได้รับอนุญาตก่อนจึงจะ update ลงในตารางได้ - อาจแนะนำให้เปลี่ยน Use Case ได้ หากพบว่าเป็น Use Case ที่ไม่เหมาะเป็น AI Use Case จริง เนื่องจากมีความยากลำบากในการกรอก Canvas [Optional] ให้ Codex ทำ SKILL.md เก็บไว้ แล้ว Re-use SKILL กับอีก 1 Use-case แล้ว update ใส่ตารางเดิม - ถ้าคำตอบออกมาไม่ดี สามารถนำตัวอย่างใน Slide ก่อนหน้า ใส่เป็น Example ให้กับ AI ได้					
2						
3						
4						
5						



IRIS : LAB2

IRIS Activity

Lab 2: Data-to-Decision Map

ลากเส้นจาก Trigger ไปจนถึง Evidence Log

Lab นี้ใช้ตรรกะว่า Use Case ไม่ได้หยุดที่โมเดล แต่เดินครบวงจรจนเกิด action และหลักฐานตาม SOP

1. Trigger: เหตุการณ์ใดเริ่ม workflow เช่น batch start, threshold breach, truck arrival, scheduled review
2. Data Inputs: ข้อมูลมาจากไหน ความถี่เท่าไร คุณภาพอย่างไร และถ้าหายจะอย่างไร
3. Feature / Model Logic: AI ใช้สัญญาณใด สร้าง output รูปแบบใด และมี confidence metric หรือไม่
4. Decision Point: ใครตัดสินใจ threshold คืออะไร และมี approval ที่ระดับ
5. Action & SLA: หลังตัดสินใจแล้วทำอะไร ใครรับผิดชอบ และต้องทำภายในเวลาเท่าไร
6. Evidence Log: บันทึกอะไรบ้างเพื่อ audit และเรียนรู้หลัง action

ตัวอย่างใช้งานจริง

ถ้าเขียน map แล้วพบว่า “AI แจ้งเตือน แต่ไม่รู้ว่ามีใครต้องทำอะไร” แสดงว่า use case ยังไม่พร้อมเป็น pilot

Data-to-Decision Map คือสะพานจากโมเดลสู่การทำงานจริง



Lab 2 Example: Cold-Chain Excursion Risk Map

ตัวอย่าง map สำหรับสินค้าที่ต้องควบคุมอุณหภูมิ

**กรณีนี้ AI ไม่ได้ตัดสินใจปล่อยหรือ hold เอง แต่ช่วยจัดลำดับ shipment ที่ควร
ตรวจสอบและเตรียม evidence package ให้ QA**

Trigger: รถขนส่งถึง Distribution Center และ upload temperature logger data

Data Inputs: temp ทุก 15 นาที, route, dwell time, door-open, product TTI, lot ID, customer shelf-life requirement

Model Output: excursion pattern + risk score + predicted shelf-life remaining + confidence

Decision Point: Logistics Supervisor ตรวจสอบ score; QA review ถ้า score > threshold หรือ shelf-life remaining ต่ำ

Action & SLA: hold for inspection ภายใน 30 นาที หรือ release ตาม SOP หลัง QA sign-off

Evidence Log: temp graph, route ID, model version, threshold, human decision, corrective action, final disposition



Lab 2: Data-to-Decision Map


เลือก 2 use cases ที่สนใจที่สุด แล้วเขียน data pipeline ตั้งแต่ trigger จนถึง evidence log — ถ้า action ไม่ชัด หรือไม่มี human checkpoint แปลว่า use case ยังไม่สมบูรณ์

Trigger	เหตุการณ์ใดทำให้ workflow เริ่มทำงาน? (batch start / threshold breach / scheduled / on-demand)
Data Inputs	ระบุ data type, source system, sampling frequency, data quality assumption และ missing data plan
Feature Engineering	ต้องแปลง raw data เป็น features อะไร? (lag features, rolling stats, ratio, encoded category)
Model Logic	AI ต้องทำอะไร: classify / predict / rank / recommend / detect anomaly / generate — ระบุ output format และ confidence metric
Decision Point	ใครต้องตัดสินใจ? ระดับ threshold ที่ trigger action คืออะไร? มีกี่ approval tier?
Action & SLA	หลังตัดสินใจแล้วทำอะไรต่อ? ใครรับผิดชอบ? ต้องทำภายในเวลาที่ขั้วโมงตาม SOP?
Evidence Log	บันทึก: timestamp, lot/batch, model version, confidence score, human decision, corrective action ตาม GMP audit trail

USE CASE A	USE CASE B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B
Use Case A	Use Case B

Lab 2: Data-to-Decision Map

เลือก 2 use cases ที่สนใจที่สุด แล้วเขียน data pipeline ตั้งแต่ trigger จนถึง evidence log — ถ้า action ไม่ชัด หรือไม่มี human checkpoint แปลว่า use case ยังไม่สมบูรณ์



Map	Use Case [A]	Use Case [B]	...
Triggers			
Data Inputs			
Feature Engineering			
Model Logic			
Decision Point			
Action & SLA			
Evidence Log			



IRIS : LAB3

IRIS Activity

Lab 3: Feasibility & Risk Scoring Matrix

ให้คะแนน Top 2-3 Use Cases เพื่อเลือก Hero

Lab นี้ให้ทีมถกกันด้วยเหตุผล ไม่ใช่รวมคะแนนแบบอัตโนมัติ เพราะแต่ละคะแนนมีนัยต่อการทำงานจริง

ให้คะแนน 1-5 ใน 5 มิติ: data, integration, interpretability, compliance control, business impact

ต้องเขียน rationale ทุกคะแนน เช่น “Data = 3 เพราะมี 6 เดือน แต่ label ยังไม่สม่ำเสมอ”


ระบุ top 2 risk items ที่ต้องแก้ก่อน pilot เช่น label quality, API access, SOP approval, QA workload

อย่าดูแค่ผลรวม ให้ดูเงื่อนไขขั้นต่ำ: Impact ≥ 4 และ Compliance control ≥ 3

สรุปว่า use case ใดเป็น Hero, use case ใดเป็น roadmap และ use case ใดควรพักไว้ก่อน

ตัวอย่างใช้งานจริง

ตัวอย่าง score: Cap defect vision = Data 3, Integration 4, Interpretability 3, Compliance 4, Impact 4 → เหมาะเป็น Hero ถ้า label defect พร้อมภายใน 4 สัปดาห์



คะแนนที่ดีต้องมีเหตุผลและแผนลดความเสี่ยงประกอบ

Lab 3: Feasibility & Risk Scoring Matrix

ให้คะแนน 1–5 (1 = ต่ำ/ยังไม่พร้อม / เสี่ยงสูง, 5 = สูง/พร้อม/ควบคุมได้ดี) — คูณผลรวม + อภิปรายเหตุผล อย่างใดตัวเลข

Use Case Name	Data Readiness	Integration Readiness	Interpretability & Explainability	Compliance Risk Control	Business Impact	Rationale สั้น ๆ
---------------	----------------	-----------------------	-----------------------------------	-------------------------	-----------------	------------------

Work with Codex (Optional):

- เขียน Prompt Codex-as-Judge ตาม Criteria ใน Slide ก่อนหน้า
 - ควรต้องมีการเขียน Criteria ให้ชัดเจนว่า ให้ 1 เมื่อใด, 2 เมื่อใด, ..., 5 เมื่อใด (ใช้ ChatGPT / Codex ช่วย Refine Criteria ได้)
- ให้ Codex อ่าน Output จาก Lab 1, 2 แล้ววิเคราะห์ Feasibility and Risk Scoring Matrix พร้อม Output Excel เป็นตารางดังรูป พร้อม Rationale สั้น ๆ ที่คอลัมน์สุดท้าย



IRIS : LAB4-5

IRIS Activity

Lab 4–5: Hero Use Case Canvas + KPI Tree + ROI

รวมทุกอย่างให้เป็น proposal ที่พร้อมนำเสนอ

ขั้นสุดท้ายให้เลือก use case เดียวและเขียนให้ครบระดับ pilot-ready พร้อม KPI และสมมติฐาน ROI ที่ตรวจสอบได้

Hero Canvas: ชื่อ use case, business problem, baseline, decision owner, data input, AI output, human checkpoint

Compliance Boundary: ระบุ AI ห้ามทำอะไรเอง และต้องมี approval ที่จุดใด



Pilot Scope: 1 line/1 site/1 route/1 product family, ระยะเวลา 3 เดือน, success/failure criteria

KPI Tree: business outcome → primary KPI → leading indicators → data source → owner/frequency

ROI Hypothesis: baseline, target, value THB/year, implementation cost, assumption และ caveat

ตัวอย่างใช้งานจริง

Closing prompt สำหรับทีม: “ใน 90 วันแรก เราจะพิสูจน์อะไร ใช้ข้อมูลจากไหน ใครต้องเปลี่ยนพฤติกรรม และถ้า KPI ไม่ดีขึ้น เราจะรู้ได้อย่างไรว่าเป็นเพราะข้อมูลโมเดล หรือ workflow?”



ROI = มูลค่าที่ลดได้ - ต้นทุน Pilot

จบ Day 2 ด้วย proposal ที่ใช้คุยต่อเรื่อง Pilot ได้ทันที

Closing: จาก Use Case สู่ Pilot Roadmap

สิ่งสำคัญไม่ใช่ว่าการใช้ AI มากที่สุด แต่คือการเลือก Use Case ที่วัดผลและควบคุมความเสี่ยงได้ดีที่สุด

ข้อความสรุปสำหรับผู้เรียน


AI Project ที่ดีเริ่มจาก measurable decision ไม่ใช่เริ่มจาก model name

Use Case ที่พร้อม Pilot ต้องตอบ data, decision, owner, compliance boundary และ KPI ได้ครบ

ความปลอดภัยอาหารและ human sign-off ต้องถูกออกแบบตั้งแต่ต้น ไม่ใช่เติมภายหลัง

Pilot ที่เล็กพอและวัดผลชัดเจน มีโอกาส scale มากกว่าโครงการใหญ่ที่ไม่มี baseline

Hero Use Case วันนี้ควรกลายเป็น action plan 3 เดือน พร้อม owner และ success criteria



Use Case
Proposal

Data Plan

Pilot
Execution

KPI Review

Scale / Stop
Decision

Good AI projects do not start from models. They start from measurable decisions.

Feasibility Filter: ประเมิน Use Case ก่อนลงแรงพัฒนา

Data Readiness

- มี historical data ≥ 6 เดือน ครอบคลุม process variation ที่สนใจหรือไม่
- Missing rate $< 15\%$ หรือมี imputation strategy ที่ QA ยอมรับ
- Data ถูก timestamp และ lot-linked ตาม batch record ที่ traceable ใหม่
- มี data governance: owner, access control, retention policy ชัดหรือไม่

Integration Readiness

- ต่อเข้า MES / ERP / LIMS / WMS / TMS ผ่าน API หรือ data lake ได้ไหม
- Latency requirement: real-time (< 1 s) vs near-real-time (< 5 min) vs batch (daily)
- IT security ยอมรับ cloud inference หรือต้องการ on-premise deployment
- มี sandbox/staging environment สำหรับทดสอบ integration ก่อน go-live

Interpretability

- Operators และ QA สามารถเข้าใจเหตุผล (feature importance / SHAP values) หรือไม่
- Model output ต้องอธิบายได้ใน language ของ user (ไม่ใช่แค่ score)
- สามารถ override AI recommendation ได้เสมอ และมี log ของการ override
- มี human-readable confidence threshold ที่ define action level

Compliance Risk Control

- AI decision กระทบ HACCP CCP / OPRP หรือ GMP critical process ใหม่
- มี documented safety boundary ว่า AI ห้าม make final decision ด้าน release/recall
- Audit trail บันทึก model version, input, output, human decision ตาม §21 CFR 11 หรือ ISO 22000
- Regulatory authority (อย. / FDA / EFSA) ยอมรับ AI-assisted decision ใน context นี้หรือไม่

Business Impact

- ประมาณ financial impact ได้: ลด COPQ $\times \% = y$ THB/year; baseline คืออะไร
- มี sponsor ระดับ manager ขึ้นไปที่ commit ทรัพยากรและ process change
- Time-to-value: คาดว่า pilot result เห็นภายใน 3–6 เดือนได้หรือไม่
- หากระบบล้มเหลว process fallback ยังทำงานได้โดยไม่กระทบ food safety

Hero Use Case ต้องมี Business Impact ≥ 4 และ Compliance Risk Control ≥ 3 ก่อนเลือกเป็น hero — ถ้า Impact สูงแต่ Data Readiness = 1 ให้จัดเป็น Roadmap item แทน

Lab 4: Hero Use Case Canvas — Pilot-Ready Proposal

กรอกให้ครบทุกช่อง ถ้ากรอกไม่ได้ แปลว่ายังต้องลดขอบเขตหรือเลือก use case ใหม่ — ผ่านเกณฑ์เมื่อตอบ [data · decision · owner · compliance boundary · KPI] ได้ครบ

Hero Use Case Name ระบุชื่อ use case พร้อม domain (Production / QA / Distribution / Cost)	Human-in-Loop Checkpoint ระบุจุดที่มนุษย์ต้องตรวจสอบและอนุมัติก่อน action — AI ห้ามทำแทนใน critical decision
Business Problem & Baseline ปัญหาที่เกิดขึ้นจริง: ระบุ baseline metric ปัจจุบัน เช่น FPY = 87%, COPQ = 2.3M THB/yr	Compliance & Safety Boundary ระบุ GMP / HACCP / ISO 22000 clause ที่เกี่ยวข้อง + decision ที่ AI ห้ามทำโดยอัตโนมัติ
Decision Owner & Authority Level ระบุตำแหน่ง, ระดับ approval (supervisor / QA manager / plant director), SOP reference	Required Systems & Integration ระบุ MES / ERP / LIMS / SCADA / WMS ที่ต้องเชื่อมต่อ + API หรือ data lake approach
Data Inputs & Quality Assessment ระบุ data type, source, sampling rate, missing rate % และ action if data unavailable	Expected Action & SLA หลัง AI output → ทำอะไร → ใครรับผิดชอบ → ต้องทำภายในกี่ชั่วโมง ตาม SOP
AI Output Format & Confidence Metric AI ส่งออกมาในรูป: score / class + confidence % / recommendation list / anomaly flag	Pilot Scope & Success Criteria ทดสอบที่ไหน (1 line / 1 site), กี่เดือน, นับ success เมื่อ KPI target ผ่าน threshold ไດ

Lab 4: Hero Use Case Canvas — Pilot-Ready Proposal

กรอกให้ครบทุกช่อง ถ้ากรอกไม่ได้ แปลว่ายังต้องลดขอบเขตหรือเลือก use case ใหม่ — ผ่านเกณฑ์เมื่อตอบ [data · decision · owner · compliance boundary · KPI] ได้ครบ

Hero Use Case Name	Human-in-Loop Checkpoint
ระบุชื่อ use case พร้อม domain (Production / QA / Distribution / Cost)	ระบุจุดที่มนุษย์ต้องตรวจสอบและอนุมัติก่อน action — AI ห้ามทำแทนใน critical decision
Business Problem & Baseline	Compliance & Safety Boundary
ปัญหาที่เกิดขึ้นจริง: ระบุ baseline m THB/yr	ห้ามทำ
Decision Owner & Authority	lake
ระบุตำแหน่ง, ระดับ approval (su SOP reference)	
Data Inputs & Quality Asses	
ระบุ data type, source, sampling rate, missing rate % และ action if data unavailable	หลัง AI output → ทำอะไร → ใครรับผิดชอบ → ต้องทำภายในกี่ชั่วโมง ตาม SOP
AI Output Format & Confidence Metric	Pilot Scope & Success Criteria
AI ส่งออกมาในรูปแบบ: score / class + confidence % / recommendation list / anomaly flag	ทดสอบที่ไหน (1 line / 1 site), กี่เดือน, นับ success เมื่อ KPI target ผ่าน threshold ไດ

Work with Codex (Optional):

- Prompt Codex ช่วยทำ Lab 4 สรุปเป็น Excel

Lab 5: KPI Tree & ROI Hypothesis

KPI Tree: เชื่อม Business Outcome → Primary KPI → Leading Indicator → Data Source → Owner

Business Outcome	Primary KPI (Lagging)	Leading Indicator (Early Signal)	Data Source & Measurement	Owner & Frequency
			Work with Codex (Optional): - Work with Codex (Optional): - Prompt Codex ช่วยทำ Lab 4 สรุปเป็น Excel 2 Sheets : KPI Tree, ROI Hypothesis	

ROI Hypothesis — ระบุ financial impact ของ hero use case พร้อม assumption ที่ชัดเจน

Impact Category	Baseline (ปัจจุบัน)	Target (หลัง deploy)	Business Value THB/yr (ประมาณ)	Key Assumption & Caveat
ลดของเสีย / Rework / Scrap				
ลด Complaint / Claim / Recall cost				
ลด Downtime / Energy / Utility				
ลดเวลาตรวจสอบ / Hold-to-Release lead time				

- รวบรวม Output ทั้งหมดตั้งแต่ Lab 1 - Lab 5 นำมาจัดทำ Final Proposal Report ประมาณ 1-2 หน้า A4
- Save เป็น Final-Proposal-Day 2.docx

เกณฑ์ผ่าน Day 2 & Deliverables

01

AI Use Case Proposal (Structured)

ระบุครบ: pain point + baseline metric · data input + quality · AI function + model type · decision point + authority · compliance boundary · expected action + SLA

02

Hero Use Case Selection Rationale

อธิบายเหตุผลที่เลือก use case นี้แทนตัวเลือกอื่น: feasibility score comparison · data readiness assessment · business impact vs risk trade-off

03

KPI Tree Draft + ROI Hypothesis

เชื่อม business outcome → primary KPI → leading indicator → data source → owner · พร้อม ROI estimate พร้อม assumption และ caveat ที่ชัดเจน

✓ เกณฑ์ผ่าน: ทีมตอบได้ว่า use case ใช้ข้อมูลอะไร · ตัดสินใจเรื่องอะไร · ใครอนุมัติ · compliance boundary ที่ชัด · วัดผลด้วย KPI ไດ · pilot scope เล็กสุดคืออะไร



APPENDIX

IRIS : USE CASE BANK

Information for Lab 1 & Lab 2

8 อุตสาหกรรม · 24 Use Cases ระดับ Production-Ready

แต่ละ use case ระบุ: data requirements · model type · integration target · compliance risk · KPI baseline
เลือกตามความพร้อมของข้อมูลและ decision authority ในองค์กร ไม่ใช่ตามความหือหา

01

Rice · Flour · Starch · Grain

02

Agro-Industrial · Meat ·
Seafood · Frozen

03

Bakery · Dairy · Honey ·
Health Foods

04

Non-Alcoholic Beverages

05

Alcoholic Beverages &
Breweries

06

Food Service & Catering

07

Food Chain · Ingredients ·
Packaging

08

Training · R&D · Technology
Services

วิธีอ่าน Use Case Bank ให้ได้ประโยชน์

Use Case Bank ไม่ใช่รายการให้คัดลอก แต่เป็นคลังไอเดียที่ต้องปรับตามบริบทโรงงาน

ทุก use case ต้องอ่านผ่านเลนส์ 5 อย่าง: data, AI function, integration, compliance risk และ KPI

Data requirements: โรงงานของเรามีข้อมูลเหล่านี้จริงหรือไม่ คุณภาพเป็นอย่างไร

Model / Function: AI ต้อง classify, predict, rank, recommend, detect หรือ generate

Integration target: ต้องเชื่อมกับ MES, LIMS, ERP, WMS, TMS, CMMS หรือ dashboard ไດ

Compliance risk: กระทาบ HACCP, GMP, ISO 22000, BRC/IFS, FDA, Thai FDA หรือ retailer spec หรือไม่

Primary KPI: ถ้าทำสำเร็จ ตัวเลขใดควรดีขึ้นอย่างเห็นได้ชัด

ตัวอย่างใช้งานจริง

หลักเลือก: อย่าเลือก use case เพราะช็อกกันสมัย ให้เลือก use case ที่ pain point มีข้อมูลพอมือ owner ชัด และ safety boundary ควบคุมได้

Use Case Bank คือจุดเริ่มต้นของการตั้งคำถาม ไม่ใช่คำตอบสำเร็จรูป

Data

Function

Integration

Compliance

KPI

Rice · Flour · Starch · Grain Processing

ข้าว แป้ง สตาร์ช และธัญพืชแปรรูป

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Adaptive Moisture & Milling Yield Optimization	Moisture sensor (NIR), drying temp log, mill setting, grain grade CoA, reject rate/shift	Gradient Boosting (yield predict) + optimization solver (drying window)	MES batch record, SCADA drying control, ERP lot cost	GMP มาตรฐาน grain storage; NIR calibration certificate ต้องมีก่อน deploy	Yield % broken grain %, energy/ton, FPY by grade
Vision Grading: Discoloration, Foreign Material & Defect Classification	High-res camera images (≥ 5MP), defect label per lot (1,000+ images/class), supplier CoA	CNN (ResNet/EfficientNet) + SHAP explainability layer for audit	LIMS defect record, ERP supplier quality module, QC dashboard	ISO 4930 grain quality standard; false-reject rate ต้องมี acceptance criteria	FPY %, false reject rate %, complaint rate/month, inspection throughput/hr
Storage Mycotoxin & Spoilage Risk Scoring	Warehouse RH/temp logger, dwell time, periodic lab aflatoxin result, pest inspection log	Multivariate scoring model + Bayesian update เมื่อมี new lab result	WMS lot location, LIMS mycotoxin result, ERP hold/release workflow	Codex Alimentarius mycotoxin limit; HACCP CCP monitoring record	Hold rate %, spoilage loss kg, time-to-release hr, aflatoxin out-of-limit incidents

Industry 01: Rice · Flour · Starch · Grain

เหมาะกับโรงงานที่มีข้อมูล moisture, warehouse condition, defect images และ lot quality

**กลุ่มนี้เน้น yield, grading, storage risk และ mycotoxin เพราะคุณภาพ
วัตถุดิบและสภาพจัดเก็บส่งผลต่อมูลค่าสินค้าโดยตรง**

Adaptive Moisture & Milling Yield Optimization: ใช้ moisture sensor, drying temp, mill setting และ grain grade เพื่อเพิ่ม yield

Vision Grading: ใช้ภาพความละเอียดสูงจำแนก discoloration, foreign material และ defect ลดภาระ QC

Storage Mycotoxin & Spoilage Risk Scoring: ใช้ RH/temp, dwell time, lab result และ pest log เพื่อจัดลำดับ lot เสี่ยง

Decision owner มักเป็น production/QC/warehouse โดย QA ต้องอนุมัติกรณี hold/release

KPI หลัก: yield %, broken grain %, FPY by grade, hold rate, spoilage loss, time-to-release

ตัวอย่างใช้งานจริง

Hero candidate: “Mycotoxin risk scoring สำหรับ warehouse lot” ดีเมื่อมี temp/RH logger และผล lab ย้อนหลังพอ แต่ต้องวาง boundary ว่า AI ให้ risk score ไม่ใช่ release decision

Grain use case มักเริ่มได้ดีถ้าข้อมูล lot และ warehouse condition เชื่อมกัน



Grain processing and sensor monitoring

Integrated Agro-Industrial · Meat · Seafood · Frozen Food

เกษตรอุตสาหกรรมครบวงจร เนื้อสัตว์ อาหารทะเล อาหารแช่แข็ง

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Trimming, Cooking & Glazing Yield Loss Forecasting	Raw weight, fat/moisture NIR, cook-loss curve, glaze weight, operator/shift, giveaway log	XGBoost regression (yield predict) + feature importance (shift/line/raw spec driver)	MES batch record, ERP standard cost vs actual cost, WMS finished goods weight	FDA net weight regulation; glaze % labeling compliance (CODEX); HACCP §cook CCP	Yield %, giveaway %, COPQ \$/month, operator consistency index
Cold-Chain Excursion & Remaining Shelf-Life Risk Scoring	IoT temp tracker (15-min interval), door-open event, dwell time at each node, product TTI	Time-series anomaly detection + kinetic shelf-life model (Arrhenius-based prediction)	TMS route tracking, WMS FEFO, ERP recall readiness module	GDP (WHO/EU), FDA FSMA §117.93 cold-chain verification, retailer shelf-life spec	Excursion rate %, shelf-life remaining at delivery hr, complaint/damage claim rate
Freezer, Retort & Filler Predictive Maintenance	Vibration sensor, motor current (3-phase), retort pressure/temp log, maintenance ticket history	LSTM (time-series anomaly) + survival analysis (failure probability by operating hrs)	CMMS maintenance order, MES line stop record, ERP spare parts inventory	Pressure vessel inspection certificate; retort scheduled maintenance §HACCP	Unplanned downtime hr/month, MTBF improvement, maintenance cost/unit

Industry 02: Meat · Seafood · Frozen Food

เหมาะกับการลด yield loss คุ่ม cold-chain และลด downtime อุปกรณ์ critical

กลุ่มนี้มีมูลค่าสูงเพราะ loss เล็กน้อยแปลเป็นเงินจำนวนมาก และอุณหภูมิส่งผลต่อความปลอดภัย/คุณภาพโดยตรง

Yield Loss Forecasting: ใช้ raw weight, NIR, cook-loss, glaze weight, operator/shift และ giveaway log

Cold-Chain Shelf-Life Risk: ใช้ temperature tracker, door-open, dwell time และ product TTI เพื่อจัดลำดับ shipment เสี่ยง

Predictive Maintenance: ใช้ vibration, motor current, retort/freezer/filler logs และ maintenance history

Compliance risk: net weight, glaze labeling, cold-chain verification, HACCP cook/retort CCP
KPI หลัก: yield %, giveaway %, COPQ, excursion rate, shelf-life remaining, downtime, MTBF

ตัวอย่างใช้งานจริง

Hero candidate: “Yield loss forecasting ในผลิตภัณฑ์แช่แข็ง” มักให้ ROI ชัด แต่ต้องมี batch weight data และมาตรฐาน net weight compliance ชัดเจน

กลุ่มนี้เหมาะกับ use case ที่แปลผลเป็นต้นทุนได้ง่าย



Bakery · Dairy · Honey · Health & Specialty Foods

เบเกอรี่ นม น้ำผึ้ง และอาหารสุขภาพหรือเฉพาะทาง

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Fermentation / Culture / Bake Stability Recommendation	pH time-series, temperature curve, humidity, culture lot, viscosity, sensory panel score	LSTM (fermentation trajectory predict) + Bayesian optimization (process window)	MES fermentation log, LIMS sensory result, ERP batch material cost	GMP §fermentation control; culture lot traceability; pH CCP monitoring record	Out-of-spec batch rate %, consistency CV%, rework rate %, cycle time hr
Shelf-Life & Packaging Integrity Prediction	Water activity (aw), pH, O2 headspace, seal test (helium/vacuum decay), storage profile	Accelerated shelf-life regression (Arrhenius) + classification (seal fail probability)	LIMS aw/pH record, packaging QC log, ERP customer shelf-life commitment	FDA 21 CFR 101 dating; IFS Food §4.13 shelf-life determination procedure	Shelf-life prediction accuracy ± days, leak rate %, end-of-shelf complaint rate/10K units
Claim-Safe Formulation Optimization (Nutrients, Cost, Allergen)	Recipe ingredient list, nutrient composition DB, allergen matrix, regulatory constraint table	Linear/Mixed-Integer Programming solver + constraint satisfaction (claim compliance check)	ERP ingredient cost, R&D formulation DB, regulatory compliance library (อย./FDA)	CODEX nutrient claim standard; allergen labeling (EU 1169/2011, Thai GDA); อย. approval	Cost/kg reduction %, claim compliance rate %, sensory acceptance score, R&D cycle time

Industry 03: Bakery · Dairy · Honey · Health Foods

เหมาะกับการคุม fermentation, shelf-life, packaging และ claim-safe formulation

กลุ่มนี้มีความซับซ้อนด้านสูตร ความคงตัว รสชาติ และการกล่าวอ้างบนฉลาก จึงเหมาะกับ AI ที่ช่วยควบคุม variation และ constraint

Fermentation / Culture / Bake Stability: ใช้ pH, temperature, humidity, culture lot, viscosity, sensory score

Shelf-Life & Packaging Integrity: ใช้ aw, pH, O₂ headspace, seal test และ storage profile

Claim-Safe Formulation: ใช้ nutrient database, allergen matrix, ingredient cost และ regulatory constraint

Compliance risk: culture traceability, shelf-life determination, allergen labeling, nutrient claim, Thai FDA approval

KPI หลัก: out-of-spec rate, consistency CV, leak rate, end-of-shelf complaint, cost/kg, R&D cycle time

ตัวอย่างใช้งานจริง

Hero candidate: “Fermentation trajectory prediction” ดีเมื่อมี pH/time-series ต่อ batch และ sensory/lab outcome ชัด เพราะช่วยลด out-of-spec และ cycle time ได้

สูตรและการหมักเหมาะกับ AI เมื่อมี outcome feedback ที่เชื่อถือได้



Non-Alcoholic Beverages & Ready-to-Drink Products

เครื่องดื่มไม่มีแอลกอฮอล์และผลิตภัณฑ์พร้อมดื่ม

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Brix, pH, Viscosity & Flavor Drift Detection	In-line Brix refractometer, pH probe, viscometer data, hourly lab QC result, sensory note	Multivariate SPC (Hotelling T^2 / CUSUM) + SHAP for drift driver identification	SCADA/MES in-line data, LIMS lab result, ERP hold trigger workflow	Beverage standard (มอก./Codex); CCP monitoring frequency ตาม HACCP plan	Out-of-spec rate ppm, drift detection lag min, hold rate %, product consistency Cpk
Filling, Cap, Label & Foreign Material Anomaly Detection	Vision camera (cap, fill level, label), X-ray inspection log, cap torque, seam measurement	CNN anomaly detection + severity classification (critical vs minor vs cosmetic)	Production line PLC reject signal, LIMS defect log, ERP complaint tracking	HACCP §foreign material CCP; GMP Annex 11 §electronic inspection validation	FPY %, false-positive rate %, consumer complaint rate, line throughput impact
Expiry Risk & Demand-Aware Distribution Planning	Demand forecast, inventory lot age (WMS), route distance/time, retailer sell-through rate	Demand forecasting (Prophet/SARIMA) + FEFO risk scoring + route optimization	WMS FEFO module, TMS route engine, ERP sales order, retailer EDI data	FSMA §117 distribution control; retailer minimum shelf-life requirement (typically 2/3 of total)	Expiry write-off %, OTIF %, stockout %, service level by SKU

Industry 04: Non-Alcoholic Beverages & RTD

เหมาะกับ sensor drift, packaging vision และ expiry-aware distribution

เครื่องดื่มน้ำมีข้อมูล inline และ line speed สูง จึงเหมาะกับ AI ที่จับ deviation เร็ว และคุม defect บนสายบรรจุ

Brix/pH/Viscosity/Flavor Drift Detection: ใช้ inline sensors + lab QC + sensory note

Filling, Cap, Label & Foreign Material Detection: ใช้ vision, X-ray, cap torque, seam measurement

Expiry Risk & Demand-Aware Distribution: ใช้ demand forecast, WMS inventory age, route และ retailer sell-through

Compliance risk: beverage standard, HACCP foreign material, electronic inspection validation, shelf-life requirement

KPI หลัก: out-of-spec ppm, drift detection lag, FPY, false-positive rate, complaint, expiry write-off

ตัวอย่างใช้งานจริง

Hero candidate: “Cap and fill-level anomaly detection” เหมาะกับ line ที่มี complaint สูงและมีกล้องหรือ inspection station อยู่แล้ว

Beverage use case มักเริ่มเร็วเพราะมี sensor/vision data ใกล้เคียง real-time



Beverage line inspection

Alcoholic Beverages & Breweries

เครื่องดื่มแอลกอฮอล์และโรงเบียร์

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Fermentation Performance & Alcohol Profile Prediction	Yeast vitality/viability count, sugar Brix, temperature curve, pH, ABV time-series per tank	LSTM (trajectory forecast) + anomaly flag for off-profile detection (early warning)	Brewery MES/SCADA, LIMS yeast lab, ERP batch material (malt, hop, yeast lot)	Excise Dept. ABV declaration accuracy; GMP fermentation record; yeast lot traceability	Batch consistency CV%, off-profile rate %, fermentation cycle time hr, ABV accuracy
Dissolved O₂, Carbonation, Fill-Level & Packaging Quality Control	DO meter, carbonation volume, fill level vision, seam/cap data, complaint by SKU	Multivariate SPC (individual parameters) + classifier (packaging defect type)	Packaging line PLC, LIMS DO/carbonation log, ERP complaint module, CRM	Container closure integrity §GMP; DO spec per product style (beer oxidation risk)	Packaging defect rate %, DO out-of-spec %, flatness/over-carbonation complaint rate
Utility, CIP & Energy Optimization (Water, Steam, Refrigeration)	Utility sub-meter (steam, water, electricity), CIP cycle log, production plan, downtime log	Regression (energy/utility predictor) + optimization (CIP schedule minimize water)	EMS (Energy Management System), CIP controller PLC, MES production plan	CIP validation record (microbial swab) — AI cannot reduce CIP below validated minimum	Energy/hl, water/hl, CIP cycle time, sanitation compliance rate (swab pass %)

Industry 05: Alcoholic Beverages & Breweries

เหมาะกับ fermentation profile, packaging quality และ utility optimization

โรงเบียร์มีข้อมูล process จำนวนมากจาก tank, lab และ utility ทำให้เหมาะกับ prediction และ optimization แต่ต้องระวัง regulatory declaration

Fermentation Performance & Alcohol Profile: ใช้ yeast vitality, Brix, temperature, pH, ABV time-series
DO / Carbonation / Fill-Level QC: ใช้ DO meter, carbonation, vision, seam/cap data และ complaint by SKU
Utility, CIP & Energy Optimization: ใช้ steam, water, electricity, CIP cycle, production plan และ downtime
Compliance risk: ABV declaration, yeast lot traceability, container closure, CIP validation, sanitation swab
KPI หลัก: batch consistency, off-profile rate, fermentation cycle time, packaging defect, energy/hl, water/hl

ตัวอย่างใช้งานจริง

Hero candidate: “Fermentation off-profile early warning” มีค่าเมื่อ cycle time ยาวและการแก้ไขช่วยลด batch loss แต่ต้องไม่เปลี่ยน process นอก validated range

Brewing AI ควรเริ่มจาก early warning ก่อน automation control

Fermentation Profile

Packaging QC

Utility / CIP

Energy per hl

ABV Accuracy

Food Service & Catering

บริการอาหารและจัดเลี้ยง

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Demand & Prep Planning by Menu, Site & Event Type	Booking data, historical demand (2+ yrs), weather API, event type, menu lead time, waste log	Gradient boosting (demand forecast per menu-site-day) + prep quantity recommendation	POS/ERP sales, booking system, kitchen production log, waste tracking app	Food allergen disclosure per menu item; portion accuracy for dietary/medical sites	Food waste kg/cover, stockout frequency, labor overtime hr, forecast accuracy MAPE
Hot-Hold, Cold-Hold & Service Safety Alerting (Digital HACCP)	IoT food-safe temp probe (holding cabinet, service line), dwell timer, checklist log	Rule-based alerting engine + anomaly detection (temperature excursion pattern)	Digital HACCP platform (Squadle/FoodDocs), LIMS complaint log, supervisor escalation app	HACCP CCP: hot-hold $\geq 60^{\circ}\text{C}$, cold-hold $\leq 5^{\circ}\text{C}$; corrective action SOP with time limit	Temperature deviation incidents/site/month, corrective action lead time min, audit score
Menu Mix, Purchasing & Food Waste Cost Optimization	Sales mix by menu item, prep waste log (kg/day), purchase invoice, spoilage record, return	LP solver (menu-purchase optimization) + ABC analysis (waste driver identification)	ERP purchasing, POS mix report, inventory management, supplier order system	Nutritional balance for institutional catering (school/hospital meal standard)	Food cost %, waste kg/cover, cost per cover, purchase variance vs budget

Industry 06: Food Service & Catering

เหมาะกับ demand planning, digital HACCP และ waste/cost optimization

บริบทนี้ต่างจากโรงงานตรงที่ demand ผันผวนรายวันและ safety control เกิดกระจายตาม site หรือ event

Demand & Prep Planning: ใช้ booking, historical demand, weather, event type, menu lead time และ waste log

Hot-Hold / Cold-Hold Safety Alerting: ใช้ food-safe temp probe, dwell timer และ checklist log

Menu Mix & Food Waste Cost Optimization: ใช้ sales mix, prep waste, purchase invoice และ spoilage record

Compliance risk: allergen disclosure, hot-hold/cold-hold limits, corrective action SOP, nutrition standard

KPI หลัก: waste kg/cover, stockout, labor overtime, temp deviation, corrective action lead time, food cost %

ตัวอย่างใช้งานจริง

Hero candidate: “Demand & prep planning by menu/site/event” เหมาะถ้ามี booking/POS/waste log อย่างน้อย 1–2 ปี และทีมครัวพร้อมปรับ production plan

Food service AI ต้องสร้างสมดุลระหว่าง waste, availability และ safety



Food service planning and analysis

Food Chain · Ingredients · Additives · Packaging & Equipment

ห่วงโซ่อาหาร วัตถุดิบ สารเติมแต่ง บรรจุภัณฑ์ และอุปกรณ์สนับสนุน

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Supplier & Incoming Lot Quality Risk Scoring	CoA per lot, delivery condition log, incoming inspection result, supplier rejection history	Weighted scorecard model + gradient boosting (predict incoming fail probability by supplier)	ERP supplier quality module, LIMS incoming result, procurement approved supplier list	ISO 22000 §8.4 supplier control; HACCP raw material CCP; customer supplier audit requirement	Incoming defect rate %, hold rate %, supplier corrective action response time, COPQ supplier
Packaging Film Variation & Seal Failure Prediction	Film lot CoA (gauge, COF, seal strength), seal temp/pressure/dwell, leak test result	Regression (seal strength predictor) + classification (leak fail probability by lot × machine)	Packaging line SPC system, LIMS seal test, ERP film lot inventory, quality dashboard	Container closure integrity for aseptic/MAP products; GMP packaging record §validation	Seal failure rate %, rework %, film utilization efficiency, consumer complaint rate
Spare Parts & Equipment Support Prioritization	Machine criticality matrix, failure history (MTBF), parts lead time, current stock, downtime cost	Survival analysis (failure probability) + criticality-weighted parts recommendation	CMMS (SAP PM / Maximo), ERP parts inventory, supplier lead time API	PM schedule per equipment validation record; food-contact equipment: NSF/3A sanitary standard	Unplanned downtime hr, parts stockout rate %, service response time hr, maintenance cost/unit

Industry 07: Ingredients • Packaging • Equipment

เหมาะกับ supplier risk, packaging failure และ spare parts prioritization

**กลุ่มนี้ช่วยลดปัญหาก่อนเข้าถึงสายผลิต เพราะวัตถุดิบ บรรจุภัณฑ์ และอุปกรณ์
เป็นต้นเหตุของ defect จำนวนมาก**

Supplier & Incoming Lot Quality Risk: ใช้ CoA, delivery condition, incoming inspection และ rejection history

Packaging Film Variation & Seal Failure: ใช้ film CoA, seal temp/pressure/dwell และ leak test result

Spare Parts & Equipment Support Prioritization: ใช้ machine criticality, failure history, lead time, stock และ downtime cost

Compliance risk: supplier control, raw material CCP, container closure integrity, sanitary standard

KPI หลัก: incoming defect, hold rate, supplier response time, seal failure, parts stockout, service response

ตัวอย่างใช้งานจริง

Hero candidate: “Packaging seal failure prediction” มักคุ้มค่าเมื่อ defect เกิดจาก film lot × machine setting และมี leak test result ย้อนหลังเชื่อมกับ production record

ป้องกันต้นเหตุใน supply chain มักถูกกว่าแก้ที่ปลายสายผลิต



Training · Research & Development · Technology Services

การฝึกอบรม วิจัย และบริการเทคโนโลยี

Use Case	Key Data Inputs	Model Type	Integration	Compliance Risk	Primary KPI
Competency Gap Analysis & Personalized Learning Path	Pre/post assessment score, supervisor 360 rating, project quality output, attendance, role profile	Clustering (learner segment) + recommendation engine (learning path by skill gap × role)	LMS (Moodle/SuccessFactors), HRIS role profile, performance management system	Training record requirement per GMP §personnel competency; ISO 22000 §7.2	Skill uplift Δ score, training completion rate, post-training deviation reduction, project quality score
Research Trial Optimization & Experiment Prioritization (DoE-AI)	Trial parameter setting, lab result (texture, pH, water activity), sensory score, cost per trial	Bayesian optimization (next experiment recommendation) + Gaussian Process surrogate model	ELN (Electronic Lab Notebook), LIMS, R&D project management (JIRA/Confluence)	GLP (Good Laboratory Practice) for regulated trials; IP protection for formulation data	Time-to-insight reduction %, trial success rate %, cost per trial, speed-to-market days
Technology Pilot Readiness & Portfolio Prioritization	Data source assessment, integration complexity score, user owner survey, compliance risk map	Weighted scoring model + portfolio prioritization matrix (impact vs readiness quadrant)	Project portfolio tool (Planview/Jira), IT architecture review, business case template	Data privacy: PDPA (Thailand) / GDPR for any PII in training data; vendor DPA	Portfolio readiness score, pilot-to-production conversion rate %, adoption rate %, ROI realization

Industry 08: Training · R&D · Technology Services

AI ใช้กับคน ความรู้ การทดลอง และ portfolio ได้เช่นกัน

ไม่ใช่ทุก Use Case ต้องเริ่มที่ production line บางองค์กรอาจเริ่มจาก training, R&D หรือ project portfolio เพื่อสร้าง readiness ก่อน

Competency Gap Analysis: ใช้ pre/post assessment, supervisor rating, project output, attendance และ role profile

DoE-AI Experiment Prioritization: ใช้ trial parameter, lab result, sensory score, cost per trial

Technology Pilot Readiness: ใช้ data assessment, integration complexity, user owner survey และ compliance risk map

Compliance risk: GMP training record, GLP, IP protection, PDPA/GDPR, vendor DPA

KPI หลัก: skill uplift, completion, trial success rate, time-to-insight, pilot-to-production conversion

ตัวอย่างใช้งานจริง

Hero candidate: “Technology pilot portfolio prioritization” ดีสำหรับองค์กรที่มีหลายไอเดีย AI แต่ทรัพยากรจำกัด เพราะช่วยเลือก project ที่ impact สูงและ readiness ดี

Use Case ด้านคนและ R&D ช่วยสร้างฐานก่อน scale AI ใน production



Workshop and portfolio prioritization

Feasibility Filter: 5 มิติก่อนเลือก Hero Use Case

ให้คะแนนเพื่อสร้างบทสนทนา ไม่ใช่เพื่อให้ตัวเลขตัดสินแทนคน

หลังจากมี use case หลายตัว ก็ต้องประเมินความพร้อมและความเสี่ยงก่อนเลือกกรณีที่เหมาะกับ pilot

Data Readiness: มีข้อมูลพอ คุณภาพพอ และ traceable พอหรือไม่


Integration Readiness: ระบบเชื่อมต่อได้จริงไหม latency เท่าไร และ IT security รับผิดชอบได้ไหม

Interpretability: คนใช้เข้าใจ output เหตุผล และ confidence ได้หรือไม่

Compliance Risk Control: มี safety boundary, human sign-off และ audit trail หรือไม่

Business Impact: ผลลัพธ์มีมูลค่าและ sponsor พร้อมเปลี่ยนกระบวนการหรือไม่

Hero Use Case ควรมี Business Impact ≥ 4 และ Compliance Risk Control ≥ 3 ถ้า impact สูงแต่ data readiness ต่ำ ให้จัดเป็น roadmap item แทน



คะแนนช่วยให้ทีมเห็น trade-off ระหว่างความคุ้มค่าและความพร้อม

Data Readiness Scoring: ให้คะแนนอย่างไร

คะแนนข้อมูลต้องดูความเหมาะสมกับ Use Case ไม่ใช่จำนวนข้อมูลอย่างเดียว

Data Readiness สูงหมายถึงข้อมูลเพียงพอ เชื่อถือได้ เชื่อมกับกระบวนการ และใช้งานใน pilot ได้โดยไม่ต้องสร้างระบบใหม่ทั้งหมด

- 1 คะแนน: ข้อมูลอยู่กระจัดกระจาย ไม่มี owner หรือไม่มี label/outcome ที่จำเป็น
- 2 คะแนน: มีข้อมูลบางส่วน แต่ missing สูง ไม่ lot-linked หรือรูปแบบไม่สม่ำเสมอ
- 3 คะแนน: มีข้อมูลย้อนหลังพอเริ่ม pilot แต่ต้อง clean, align หรือ label เพิ่ม
- 4 คะแนน: ข้อมูลพร้อมในระบบหลัก มี timestamp, owner และ quality check พื้นฐาน
- 5 คะแนน: ข้อมูล audit-ready, integrated, monitored และมี governance ชัดเจน

ตัวอย่างใช้งานจริง

Use Case vision inspection อาจได้ Data Readiness 2 ถ้ามีกล้องแต่ยังไม่มี labeled defect; แต่จะขึ้นเป็น 4 เมื่อมี image dataset, defect taxonomy และ QA-confirmed labels

Data score ต้องมาจากหลักฐาน ไม่ใช่ความรู้สึกว่า “น่าจะมีข้อมูล”

1
ยังไม่พร้อม

2
มีบางส่วน

3
เริ่ม Pilot ได้

4
พร้อมดี

5
Audit-ready

Integration Readiness: ระบบจะต่อกันได้จริงหรือไม่

AI ที่ใช้จริงต้องเข้า workflow และระบบเดิมขององค์กรได้

Integration เป็นจุดที่ทำให้ demo กลายเป็น production หรือหยุดอยู่แค่ไฟล์ทดลอง


ระบบต้นทาง: MES, SCADA, LIMS, ERP, WMS, TMS, CMMS, LMS หรือ data lake มี API หรือ export ได้หรือไม่

Latency: ต้อง real-time, near-real-time, hourly, daily หรือ weekly เพราะความต้องการไม่เท่ากัน

Deployment: cloud, on-premise หรือ hybrid และ IT/security ยอมรับแบบใด

User interface: operator/QA เห็น output ที่ไหน และใช้ใน workflow ปัจจุบันได้หรือไม่

Sandbox: มี environment สำหรับทดสอบโดยไม่กระทบ production หรือไม่



Integration ที่ไม่พร้อมทำให้ AI เป็นรายงาน ไม่ใช่ระบบช่วยตัดสินใจ

Interpretability & Compliance Risk Control

ผู้ใช้งานต้องเข้าใจ และ auditor ต้องตรวจสอบได้

AI ในอาหารต้องไม่ใช่ black box ที่ให้คะแนนลอย ๆ โดยไม่มีเหตุผล ไม่มี threshold และไม่มีหลักฐานการตัดสินใจ

Interpretability: output ต้องอธิบายด้วยภาษาของ user เช่น driver, feature importance, confidence และ recommended reason

Override: ผู้ใช้ต้อง override ได้ และระบบต้องบันทึกเหตุผลของ override

Compliance boundary: ระบุว่า AI กระทำ CCP, OPRP, GMP critical process หรือ release decision หรือไม่

Human sign-off: กำหนดตำแหน่งที่ต้องอนุมัติและ SOP reference

Validation: ทดสอบ model performance, robustness, data drift และ bias ก่อน go-live

ตัวอย่างใช้งานจริง

สำหรับ supplier rejection AI ไม่ควร reject supplier เอง แต่ควรให้ risk score + evidence package เพื่อให้ procurement/QA ใช้ประกอบการตัดสินใจ

ความน่าเชื่อถือของ AI มาจากความโปร่งใสและการควบคุมความเสี่ยง

Explainable Output

Override Log

Human Sign-off

Audit Trail

Validation Plan

Business Impact & Prioritization Matrix

เลือก Use Case ที่คุ้มค่าและพร้อมพอ ไม่ใช่แค่ไอเดียที่น่าสนใจ

Business Impact ต้องประเมินด้วย baseline และมูลค่าที่เป็นไปได้ ไม่ใช่คำว่า “น่าจะดีขึ้น”

ประเมินมูลค่า: ลด COPQ, scrap, rework, complaint, downtime, energy, claim หรือ overtime ได้เท่าไร

ประเมิน time-to-value: เห็นผลใน 3-6 เดือนหรือไม่ หรือเป็นโครงการระยะยาว

ประเมิน sponsor: มีผู้จัดการที่ commit ทรัพยากรและยอมเปลี่ยน process หรือไม่

ใช้ matrix: Impact สูง + Readiness สูง = Hero Use Case; Impact สูง + Readiness ต่ำ = Roadmap item

อย่าลืม caveat: seasonality, production volume, raw material variation และต้นทุน implementation

ตัวอย่างใช้งานจริง

ถ้า Use Case A impact 5 readiness 2 อาจไม่ควรเริ่มตอนนี้ ส่วน Use Case B impact 4 readiness 4 อาจเป็น Hero เพราะพิสูจน์ผลได้เร็วกว่า

Hero Use Case ไม่จำเป็นต้องใหญ่ที่สุด แต่ต้องพร้อมพอและมีมูลค่าจริง

Readiness ↑



Business Impact →



Solution (Example)

Google Docs Link: [act2_solution_memo](#)