

WORKSHOP DAY 3

AI Workflow Automation สำหรับโรงงานอาหารมูลค่าสูง

Workflow Automation Architecture • Prototype Plan •
Executive Pitch

เปลี่ยน Hero Use Case ให้เป็นระบบตัดสินใจ
ที่ตรวจสอบได้ ไม่ใช่แค่ workflow demo

Trigger → Risk → Decision → Evidence Log




วันนี้เราจะทำอะไร

จาก Hero Use Case ไปสู่ระบบตัดสินใจที่ตรวจสอบได้

ผลลัพธ์ที่ต้องได้

- เข้าใจ workflow automation ในบริบทโรงงานอาหาร
- ออกแบบ trigger, data contract, risk logic และ decision boundary
- สร้าง prototype plan ที่ยังไม่แตะระบบ production จริง
- เตรียม executive pitch ที่ผูกกับ KPI และ ROI

เป้าหมาย: ระบบเล็ก แต่คิดครบเรื่องความเสี่ยง



ระบบตัดสินใจแบบมีหลักฐาน

ลด false alarm ด้วย trigger ที่วัดได้

คุม decision boundary ในจุดเสี่ยง

พิสูจน์ KPI / ROI จาก baseline จริง


จาก Day 2 มาสู่ Day 3

ต่อยอดจากการเลือก Hero Use Case ให้กลายเป็นระบบจริง

ความต่างของวันนี้

- Day 2 เน้นเลือก use case และประเมิน feasibility
- Day 3 เน้น architecture, control และ evidence
- ไม่เริ่มจาก model แต่เริ่มจาก decision point
- ต้องตอบได้ว่า AI ห้ามตัดสินใจเองตรงไหน

Use Case ที่ดีต้องเข้า workflow จริง



Day 3 Output

Automation Blueprint

Exception Pack

Prototype Plan

Business Case


Workflow Automation คืออะไร

ระบบที่เปลี่ยนเหตุการณ์หน้างานให้เป็น action ที่มีหลักฐาน

นิยามใช้งานง่าย

- รับสัญญาณจาก process, quality, traceability หรือ logistics
- ตรวจสอบคุณภาพข้อมูลก่อนใช้ตัดสินใจ
- คำนวณ risk หรือเลือก rule ที่เหมาะกับสถานการณ์
- ส่งให้คนที่มีอำนาจอนุมัติและเก็บหลักฐานทุกครั้ง

จุดจบไม่ใช่ dashboard แต่คือ action + evidence



หลักคิด

เริ่มจากเหตุการณ์หน้างาน แล้วจบที่หลักฐานตรวจสอบย้อนหลังได้

คำถามหลัก

ถ้าถูก audit อีก 6 เดือน จะอธิบายได้หรือไม่

ทำไมโรงงานอาหารต้องระวังมากกว่า

AI ในโรงงานอาหารกระทบ safety, quality, compliance และ brand trust

ความเสี่ยงสำคัญ

- Food safety decision มีต้นทุนความผิดพลาดสูง
- Hold / release / recall ต้องมีผู้รับผิดชอบชัดเจน
- ข้อมูลต้องย้อนกลับถึง lot, batch, route และ parameter ได้
- ✕ • ระบบต้องอธิบายได้ต่อ auditor และผู้บริหาร

Productivity ต้องไม่มาก่อน food safety

Food Safety

false negative แพงมาก: สินค้าเสี่ยงหลุดไปถึงลูกค้า

Quality

ระบบต้องเชื่อม defect, lot, operator, shift และ action

Audit

ต้องบอกได้ว่าใช้ข้อมูลชุดใด เวอร์ชันใด ใครอนุมัติ

Business

ต้องเห็นผลจริงจาก KPI ไม่ใช่แค่ demo ดูกันสมัย

Automation ที่ดีไม่ใช่ให้ AI ตัดสินใจแทนคน

AI ควรช่วยเตรียมหลักฐาน จัดลำดับความเสี่ยง และเสนอทางเลือก

หลักคิดสำหรับ supervisor

- แยก “recommendation” ออกจาก “approval” ให้ชัด
- กำหนดสิทธิ์ override ตาม role, severity และ shift
- เก็บเหตุผลของมนุษย์ ไม่ใช่แค่ปุ่ม approve/reject
- มี fallback manual เมื่อระบบหรือข้อมูลล้มเหลว

มนุษย์ยังเป็นเจ้าของ decision ที่มีความรับผิดชอบ



Controlled Action

ต้องมี owner + SLA

ต้องมี fallback เมื่อข้อมูลขาด

ต้องมี evidence log

Reference Architecture ของ Food Automation

แยกข้อมูล ตระกการตัดสินใจ และหลักฐานตรวจสอบย้อนหลัง

โครงสร้างหลัก

- Layer 1: process data จาก sensor, batch sheet, line speed
- Layer 2: quality & food safety records เช่น lab, inspection, complaint
- Layer 3: traceability context เช่น raw lot, packaging, warehouse, route
- Control plane: validation → scoring → approval → evidence archive

Layer 1: Process Data

sensor • batch sheet • line speed

Layer 2: Quality & Safety Records

lab • inspection • complaint • release

Layer 3: Traceability Context

raw lot • packaging • warehouse • route

เปลี่ยน model ได้โดยไม่ทำ traceability พัง

Validate

Score

Gate

Approve

Archive



Part 1

Trigger Engineering

เปลี่ยนเหตุการณ์หน้างานให้เป็น trigger ที่วัดได้




Trigger คืออะไร

Trigger คือเหตุการณ์ที่ทำให้ workflow เริ่มทำงาน

Trigger ที่ดีต้องมี

- นิยามเหตุการณ์ชัด เช่น temp excursion, defect spike, lab result late
- มี threshold หรือ pattern ที่วัดได้
- มี time window เช่น 10 นาที, 30 นาที, 1 shift
- มี owner และ action ถัดไป



หลักคิด

เริ่มจากเหตุการณ์หน้างาน แล้วจบที่หลักฐานตรวจย้อนหลังได้

Trigger ที่คลุมเครือจะสร้าง false alarm

คำถามหลัก

ถ้าถูก audit อีก 6 เดือน จะอธิบายได้หรือไม่

Trigger แบบ Threshold

ใช้เมื่อมี spec, limit หรือ critical limit ที่ชัดเจน

ตัวอย่าง

- อุณหภูมิห้องเย็น > 8°C ต่อเนื่อง 12 นาที
- pH หลุดช่วงที่กำหนดใน batch fermentation
- fill level ต่ำกว่า minimum legal requirement
- ผล microbiology ไม่ผ่านเกณฑ์ release

เหมาะกับ rule gate และ safety control

Threshold Trigger

ค่าเกิน spec หรือ critical limit เป็นเวลาที่กำหนด

Critical limit

Trigger แบบ Pattern

ใช้เมื่อปัญหาเกิดซ้ำตามเงื่อนไขบางอย่าง

ตัวอย่าง

- defect เพิ่มขึ้นเฉพาะ film lot เดียว
- complaint สูงเฉพาะ shift กลางคืน
- cold-chain excursion เกิดซ้ำใน route เดิม
- sensor gap เกิดซ้ำหลัง maintenance บางประเภท

Pattern บอกว่าเราควรตรวจที่ไหนก่อน

Shift A

Shift B

Shift C

Film Lot X

Line 2

Line 3

Pattern Trigger

พบ pattern ซ้ำตาม shift, line หรือ material lot

Trigger แบบ Compound Risk

ใช้เมื่อความเสี่ยงเกิดจากหลายสัญญาณพร้อมกัน

ตัวอย่าง

- temperature exposure + shelf-life เหลือน้อย + route delay
- defect spike + raw material lot ใหม่ + operator change
- pH drift + culture lot ใหม่ + sensory score ต่ำลง
- sensor gap + high-risk SKU + shipment ใกล้เคียงลูกค้า

เหมาะกับ risk scoring มากกว่า threshold เดียว

Temp exposure

12 นาที > limit

Shelf-life เหลือน้อย

เหลือ 5 วัน

Route delay

ดีเลย์ 6 ชม.

Risk Score สูงขึ้นเมื่อหลายสัญญาณเกิดพร้อมกัน

Compound Risk

เหมาะกับ decision ที่ต้องรวมหลายหลักฐาน


ลด False Alarm อย่างไร

Trigger ที่เตือนเยอะเกินไปจะทำให้คนเลิกเชื่อระบบ

วิธีลด false alarm

- ใช้ dwell time แทนการดูค่าเกินครั้งเดียว
- แยก product risk profile ตาม SKU หรือ process
- ตั้ง triage queue สำหรับ alert ที่ยังไม่ต้องหยุดทันที
- วัด precision: alert แล้วเกิด action จริงกี่เปอร์เซ็นต์

Alert ที่ดีต้องนำไปสู่ action ที่มีคุณค่า



แยก alarm ที่หยุดทันที

แยก alarm ที่เข้า triage queue

วัด precision: แจ้งแล้วต้องมี action กี่ %

แบบฝึก: เขียน Trigger ของ Use Case

ให้ทีมแปลง pain point เป็นเหตุการณ์ที่วัดได้

ให้ตอบ 5 ข้อ

- เหตุการณ์เริ่มต้นคืออะไร
- ใช้ข้อมูลใดวัดเหตุการณ์นี้
- threshold / pattern / time window คืออะไร
- ใครเป็น owner ของ trigger
- ถ้าเกิด trigger แล้ว action แรกคืออะไร

ถ้ายังเขียน trigger ไม่ได้ use case ยังไม่พร้อม
ทำ prototype

1. Automation Blueprint

2. Exception Pack

3. Prototype Plan

4. Business Case

5. Executive Pitch Draft



Part 2

Data Contract

ข้อมูลต้องมีคุณภาพพอ ก่อนให้ AI ช่วยตัดสินใจ



Data Contract คืออะไร

ข้อตกลงขั้นต่ำของข้อมูลก่อนเข้าสู่ workflow

องค์ประกอบสำคัญ

- Schema: field, format, unit และ expected range
- Owner: ใครรับผิดชอบความถูกต้องของข้อมูล
- Freshness: ข้อมูลล่าสุดพอสำหรับ decision window หรือไม่
- Lineage: รู้ต้นทางและการแปลงข้อมูลหรือไม่
- Missing-data rule: เมื่อข้อมูลขาดต้องทำอย่างไร

เขียน data contract ก่อนเขียน automation

Schema

ชื่อ field / format / unit

Owner

ใครรับผิดชอบเมื่อข้อมูลผิด

Freshness

ล่าสุดพอสำหรับ decision window หรือไม่

Lineage

รู้ต้นทางและ transformation หรือไม่

Missing-data rule

เมื่อข้อมูลขาดต้องทำอย่างไร


Data Quality Gate

ห้ามให้ข้อมูลผิดพลาดเข้าสู่ decision logic

Quality gate ควรถามว่า

- ข้อมูลครบช่วงเวลาที่ต้องใช้หรือไม่
- หน่วยถูกต้องหรือไม่ เช่น °C, นาที, kg, CFU
- ข้อมูลมาจาก source ที่ได้รับอนุมัติหรือไม่
- ถ้า data fail ต้องหยุด workflow หรือใช้ fallback rule

ข้อมูลผิด + automation เร็ว = ความเสี่ยงเร็วขึ้น



Quality Gate

ไม่ผ่าน = หยุด workflow หรือใช้ fallback rule

Freshness: ข้อมูลต้องใหม่แค่ไหน

ความสดของข้อมูลขึ้นกับประเภท decision

ตัวอย่าง decision window

- CCP หรือ line stop: ต้อง near-real-time
- defect trend: อาจใช้ทุก 15–30 นาที
- lab result review: ใช้ตามรอบการ upload
- complaint / supplier review: รายวันหรือรายสัปดาห์พอได้

อย่าใช้ข้อมูลเมื่อวานตัดสินใจเรื่องที่ต้องรู้ตอนนี้

Real-time

เช่น CCP, line stop,
temperature excursion

Hourly

เช่น defect trend, lab
proxy, maintenance
signal

Daily / Weekly

เช่น cost, complaint,
supplier review

Decision window ต้องเป็นตัวกำหนด freshness


Data Quality Gate

ห้ามให้ข้อมูลผิดพลาดเข้าสู่ decision logic

Quality gate ควรถามว่า

- ข้อมูลครบช่วงเวลาที่ต้องใช้หรือไม่
- หน่วยถูกต้องหรือไม่ เช่น °C, นาที, kg, CFU
- ข้อมูลมาจาก source ที่ได้รับอนุมัติหรือไม่
- ถ้า data fail ต้องหยุด workflow หรือใช้ fallback rule

ข้อมูลผิด + automation เร็ว = ความเสี่ยงเร็วขึ้น



Quality Gate

ไม่ผ่าน = หยุด workflow หรือใช้ fallback rule

Missing Data Policy

ข้อมูลขาดต้องมี policy ไม่ใช่แก้เฉพาะหน้า


ตัวอย่าง policy

- sensor gap < 5 นาที: ใช้ interpolation ได้เฉพาะ non-safety trend
- sensor gap > 10 นาที: ส่ง QA review
- lab result late: ไม่ให้ release อัตโนมติ
- missing lot mapping: hold evidence package จนกว่าจะ reconcile

บางช่องว่างข้อมูลเล็ก แต่ผลต่อ safety ใหญ่มาก

Sensor gap 17 นาที

ห้ามเฉลี่ยอัตโนมัติถ้าเป็น food safety decision



Policy

ต้องเขียนก่อนทำ automation

ตัวอย่าง Data Contract: Cold Chain

ใช้กับ workflow ตอบสนอง temperature excursion

Field ที่ควรกำหนด

- shipment ID, route ID, vehicle ID, pallet/lot mapping
- temperature logger frequency และหน่วย °C
- door-open event, dwell time, delivery timestamp
- shelf-life requirement และ product risk profile
- missing rule เมื่อ temp log ขาดช่วง

Data contract ทำให้ cold-chain decision ป้องกัน audit ได้

Route ID + Shipment ID

Temperature log: unit °C / frequency 5 นาที

Dwell time + door-open event

Lot / pallet / SKU mapping

Missing rule: gap > 10 นาที → QA review



Part 3

AI Logic และ Risk Logic

เลือกตรรกะให้เหมาะสมกับความเสี่ยง ไม่ใช่โมเดลเพราะดูทันสมัย



เลือก Logic ให้เหมาะกับปัญหา

AI logic มีหลายแบบและเหมาะสมกับความเสี่ยงต่างกัน

ตัวเลือกหลัก

- Rule gate: ใช้กับ limit ที่ไม่ต่อรองได้
- SPC: ใช้กับ drift และ process stability
- Anomaly detection: ใช้กับ pattern ผิดปกติที่ไม่รู้ล่วงหน้า
- ✕ • Risk score: ใช้รวมหลายหลักฐานและ uncertainty

Logic ที่ดีต้องอธิบายได้และควบคุมได้

Rule gate
critical limit / regulation

SPC
drift / process stability

Anomaly detection
pattern ที่มนุษย์เห็นซ้ำ

Risk score
รวมหลายหลักฐานและ uncertainty

Rule-Based Logic

เหมาะกับเกณฑ์ที่ชัดและต้อง audit ง่าย

การใช้เมื่อ

- มี Regulatory limit หรือ Critical limit
- Decision boundary ต้องชัดและไม่ต่อรอง
- ที่มต้องอธิบายเหตุผลแบบตรงไปตรงมา
- ข้อมูลยังไม่พอสำหรับ model ที่ซับซ้อน

Simple rule ที่ดี อาจปลอดภัยกว่า AI model ที่อธิบายยาก

IF
อุณหภูมิ > limit นานกว่า 12 นาที

THEN
ส่งเข้า QA Review / Hold

เหมาะเมื่อ
เกณฑ์ไม่ต่อรองได้และต้อง audit ได้ง่าย

Statistical Process Control

เหมาะกับการจับ drift และความนิ่งของ process

ใช้เพื่อ

- ตรวจสอบว่ากระบวนการเริ่มแกว่งผิดปกติหรือไม่
- แยก special cause ออกจาก common cause
- จับ process ที่ยังไม่หลุด spec แต่เริ่มไม่นิ่ง
- เชื่อมกับ corrective action ก่อนเกิด defect จำนวนมาก

SPC ช่วยให้เห็นปัญหาก่อน KPI เสีย

SPC
จับ drift ก่อนหลุด control limit


Anomaly Detection

เหมาะกับ pattern ใหม่หรือซ่อนอยู่ในข้อมูลจำนวนมาก

เหมาะเมื่อ

- ไม่รู้ threshold ที่ดีล่วงหน้า
- ข้อมูลเป็นภาพ sensor time-series หรือหลาย feature
- ต้องการหาเหตุการณ์ผิดปกติเร็วขึ้น
- ยังต้องมี human review เพราะ anomaly ไม่เท่ากับ defect เสมอ

Anomaly เป็นสัญญาณให้ตรวจ ไม่ใช่คำตัดสินสุดท้าย



Anomaly Detection

เหมาะกับ pattern ที่ไม่รู้ threshold ล่วงหน้า

Risk Scoring

เหมาะกับ decision ที่ต้องรวมหลายหลักฐาน

Risk score ที่ดีต้องมี

- Feature ที่อธิบายได้ เช่น exposure, shelf-life, route delay
- Calibration กับ outcome จริง
- Threshold และ uncertainty handling
- Reject option เมื่อข้อมูลไม่พอหรือความมั่นใจต่ำ

สีแดง-เหลือง-เขียวต้องมีหลักฐานรองรับ

Evidence 1
Temp exposure

Evidence 2
Shelf-life

Evidence 3
Route delay

Risk Score = 82/100

ต้องมี Calibration
คะแนนต้องสัมพันธ์กับ outcome จริง

เมื่อไรไม่ควรใช้ AI Model

บาง use case ควรเริ่มจาก rule, SOP หรือ data readiness ก่อน

สัญญาณเตือน

- ข้อมูลน้อยหรือ label ไม่น่าเชื่อถือ
- เกณฑ์ business rule ชัดเจนอยู่แล้ว
- Decision เสี่ยงสูงแต่ model อธิบายไม่ได้
- ปัญหาแท้จริงคือ SOP ไม่ถูกทำตาม ไม่ใช่ไม่มี model

อย่าใช้ AI เพื่อแก้ปัญหาก็ governance ยังไม่พร้อม

กฎชัดเจนอยู่แล้ว → ใช้ rule gate

ข้อมูลน้อยเกินไป → เริ่มเก็บข้อมูลก่อน

Decision เสี่ยงสูงและอธิบายไม่ได้ → ใช้ Human review

ปัญหาเป็น process discipline → แก้ SOP ก่อน model

False Positive vs False Negative

ต้องคุย trade-off ก่อนออกแบบ threshold

ความหมาย

- False positive: ระบบเตือนทั้งที่ไม่เสี่ยงจริง
- False negative: ระบบไม่เตือนทั้งที่มีความเสี่ยงจริง
- ใน food safety หลายกรณี false negative แพงกว่า
- ต้องกำหนด risk appetite ตามประเภท decision

False Positive

แจ้งเตือนผิด →
เสียเวลา / hold เกินจำเป็น

False Negative

ไม่เตือน case เสี่ยง →
สินค้าเสี่ยงหลุด

ความแม่นยำไม่พอ ต้องดูความผิดพลาดที่อันตรายที่สุด

ใน food safety หลายกรณี false negative มีต้นทุนสูงกว่า



Part 4

Decision Boundary

AI แนะนำได้ แต่ decision สำคัญต้องมีเจ้าของ



Decision Boundary คืออะไร

เส้นแบ่งว่า AI ทำอะไรได้ ต้องให้ใครอนุมัติ และอะไรห้ามทำ

ต้องนิยามให้ชัด

- **AI ทำได้:** เตรียมหลักฐาน ให้ score จัดลำดับงาน
- **มนุษย์ต้องอนุมัติ:** hold, release, quarantine, deviation
- **AI ห้ามทำ:** override food safety rule หรือลบ evidence log
- ทุก boundary ต้องสัมพันธ์กับ role และ severity

Boundary ที่ไม่ชัด = Accountability ไม่ชัด

AI ทำได้

รวบรวมหลักฐาน / ให้ risk score / draft narrative

มนุษย์ต้องอนุมัติ

hold / release / quarantine / deviation

AI ห้ามทำอัตโนมัติ

release lot ที่เกี่ยวกับ CCP / override rule / ลบ log

AI ทำอะไรได้บ้าง

ให้ AI เป็นผู้ช่วยตัดสินใจ ไม่ใช่ผู้มีอำนาจสุดท้าย

AI เหมาะกับงานเหล่านี้

- รวบรวมหลักฐานจากหลายระบบ
- ให้ risk score พร้อม confidence
- จัดลำดับความเร่งด่วนของ ticket
- ร่าง Non-Conformance narrative
- เสนอ corrective action alternatives

AI ทำงานเตรียมหลักฐานได้เร็วมาก

รวบรวมหลักฐานจากหลายระบบ

ให้ Risk score + Confidence

จัดลำดับความเร่งด่วน

ร่าง NC narrative

เสนอทางเลือก Corrective action

งานที่ต้องให้มนุษย์อนุมัติ

Decision ที่กระทบสินค้า กระบวนการ หรือ compliance ต้องมีผู้รับผิดชอบ

ตัวอย่าง

- ปลดหรือกักสินค้า
- เปลี่ยน process window
- ยืนยัน root cause
- อนุมัติ deviation
- สื่อสารกับลูกค้าหรือ regulator

Approval ต้องมี Rationale ไม่ใช่แค่คลิกผ่าน

ปลดหรือกักสินค้า

เปลี่ยน Process window

ยืนยัน Root cause

อนุมัติ Deviation

สื่อสารกับลูกค้าหรือ Regulator

งานที่ห้ามให้ AI ตัดสินใจอัตโนมัติ

ต้องล็อกไว้ใน policy และ system permission

ห้ามทำโดยอัตโนมัติ

- Release lot ที่เกี่ยวกับ Critical Control Point
- ยกเลิก quarantine โดยไม่มี QA approval
- สรุป recall scope เอง
- Override food safety rule
- ลบหรือแก้ evidence log หลังเกิดเหตุ

AI ไม่ควรเป็นเจ้าของ food safety disposition

Release lot ที่เกี่ยวกับ Critical Control Point

ยกเลิก Quarantine เอง

สรุป Recall scope เอง

Override food safety rule

ลบหรือแก้ evidence log

Override ต้องบันทึกอะไรบ้าง

ทุก override เป็นหลักฐานสำคัญเมื่อเกิด deviation หรือ audit

ต้องเก็บอย่างน้อย

- ชื่อและ role ของผู้อนุมัติ
- timestamp ของการตัดสินใจ
- เหตุผลและ evidence ที่ใช้ประกอบ
- Action ที่ทำจริง
- Outcome หลัง action และ post-review

Override ที่ไม่มีเหตุผลคือช่องโหว่ของ governance

Approver
ชื่อและ role

Timestamp
เวลาที่ตัดสินใจ

Rationale
เหตุผลและ evidence ที่ใช้

Outcome
ผลหลัง action


Post-review
เรียนรู้อะไรเพื่อปรับ rule

ตัวอย่าง Decision Boundary: Lot Release

ใช้ AI ช่วยรวบรวมหลักฐาน แต่ final disposition ต้องมีผู้อนุมัติ

แนวทาง

- AI สรุป risk score และ evidence package
- QA ตรวจ data completeness และ rule violation
- Supervisor ให้ข้อมูล operation context
- ผู้มีอำนาจอนุมัติ hold/release/rework
- ระบบเก็บ rationale และ outcome แบบ append-only



Boundary
AI ให้ recommendation ได้
แต่ disposition ต้องมีผู้มีอำนาจอนุมัติ

AI ควรช่วยให้การตัดสินใจดีขึ้น ไม่ใช่ลดขั้นตอน



Part 5

Evidence Log และ Auditability

ถ้าอธิบายย้อนหลังไม่ได้ ระบบยังไม่พร้อมใช้จริง



Evidence Log คืออะไร

บันทึกหลักฐานของทุก workflow run ตั้งแต่ input ถึง outcome

ต้องตอบได้ว่า

- เหตุการณ์เริ่มเมื่อไรและด้วย trigger อะไร
- ใช้ข้อมูลชุดใด เวอร์ชันใด timestamp ใด
- ใช้ rule, model หรือ prompt เวอร์ชันใด
- AI แนะนำอะไร confidence เท่าไร
- ใครอนุมัติ ทำอะไร และผลหลัง action คืออะไร

ไม่มี evidence log = workflow ใช้ตรวจสอบจริงไม่ได้

Workflow Run ID

Input data version + timestamp

Rule / model / prompt version

Output + confidence + uncertainty

Approver + rationale + outcome

Auditor อยากเห็นอะไร

คิดแบบผู้ตรวจตั้งแต่ตอนออกแบบ prototype

คำถามจาก auditor

- ใครตัดสินใจและมีอำนาจตาม matrix หรือไม่
- ตัดสินจากหลักฐานชุดใด
- ข้อมูลและ model version ตามย้อนกลับได้หรือไม่
- มี override หรือ exception หรือไม่
- ผลหลัง action ตรงกับสิ่งที่บันทึกหรือไม่

ออกแบบให้ตอบคำถาม auditor ได้ใน 5 นาที

ใครตัดสินใจ?

ตัดสินจากหลักฐานชุดใด?

ใช้ rule / model version ใด?

มี override หรือไม่?

ผลหลัง action เป็นอย่างไร?

Evidence Log ต้องเก็บอะไรบ้าง

Specification ขั้นต่ำสำหรับระบบ audit-ready

รายการหลัก

- Workflow run identifier และ timestamp
- Input data version และ source lineage
- Rule/model/prompt version
- Output, risk score, confidence และ uncertainty
- Approver, rationale, corrective action และ outcome

เก็บเฉพาะ output ไม่พอ ต้องเก็บ path ของ decision

Input data version

Rule/model/prompt version

Output + risk score + confidence

Human approval + rationale

Corrective action + outcome

Versioning: Prompt / Model / Rule

เมื่อผลลัพธ์เปลี่ยน ต้องรู้ว่าอะไรเปลี่ยน

แนวทาง

- Prompt template version สำหรับ generative AI
- Rule version สำหรับ threshold และ gate
- Model version สำหรับ prediction หรือ risk scoring
- Workflow configuration version เช่น threshold และ escalation
- Validation dataset version



Version Control

หากผลลัพธ์เปลี่ยน ต้องรู้ว่าเปลี่ยน
เพราะข้อมูล กฎ โมเดล หรือ prompt

เวอร์ชันคือภาษาของ Auditability

Append-only Log

หลักฐานต้องป้องกันการแก้ไขย้อนหลังหลังเกิด deviation

หลักการ

- เพิ่ม record ใหม่ได้ แต่ไม่ควรเขียนทับ record เดิม
- จำกัดสิทธิ์แก้ไข และเก็บ change history
- แยก correction note ออกจาก original event
- เก็บ retention policy ตามข้อกำหนดองค์กรและกฎหมาย

Log ที่แก้ไขย้อนหลังง่ายจะไม่น่าเชื่อถือ

Append-only log

สิทธิ์แก้ไขจำกัด

ห้ามลบ log หลังเกิด deviation

Log ที่ดีต้องป้องกันการแก้ไขย้อนหลัง

แบบฝึก: ออกแบบ Evidence Log

ให้ทีมกำหนด evidence ที่ต้องเก็บใน use case ของตน

ให้ตอบ

- Workflow run ID จะสร้างจากอะไร
- Input data source และ version คืออะไร
- AI output จะเก็บ confidence หรือ rationale อย่างไร
- ใครเป็น approver และต้องกรอกเหตุผลใด
- Outcome หลัง action จะติดตามเมื่อไร

อย่ารอทำ log ตอน go-live ให้คิดตั้งแต่ prototype

Workflow Run ID

Input data version + timestamp

Rule / model / prompt version

Output + confidence + uncertainty

Approver + rationale + outcome



Part 6

Prototype Plan

ต้นแบบต้องเล็ก แต่ต้องมี control พอสำหรับโรงงานจริง




Prototype ที่เล็กแต่ใช้จริงได้

Minimum viable prototype ต้องไม่ใช่แค่ demo หน้าจอสวย

Prototype ต้องมี

- Input sample 30–50 เหตุการณ์ย้อนหลังพร้อม outcome จริง
- Data validation step ก่อน AI หรือ rule logic
- Approval queue ที่บังคับกรอก rationale
- Evidence log ที่ export ได้
- Validation sheet เทียบกับ decision จริงของทีม



MVP Prototype
เล็กพอทดลองได้ แต่ต้องมี control ครบ

เล็กได้ แต่ห้ามข้าม control

Input Sample สำหรับ Prototype

ใช้ข้อมูลย้อนหลังเพื่อทดสอบว่า workflow คิดถูกหรือไม่

ข้อมูลขั้นต่ำ

- เหตุการณ์จริง 30–50 cases จาก process เดียวกัน
- มี input ครบพอสำหรับ trigger และ risk logic
- มี human decision เดิมเพื่อใช้เทียบ
- มี actual outcome เช่น release, reject, rework, complaint
- ระบุ case ที่ข้อมูลขาดหรือ exception ด้วย

Prototype ที่ไม่มี outcome จริงจะวัด value ยาก

30–50 เหตุการณ์ย้อนหลัง
ต้องมี input + outcome จริง เพื่อเทียบระบบกับการตัดสินใจเดิม

Incident data

Human decision


Actual outcome

Prototype Architecture แบบง่าย

เริ่มจาก sandbox ไม่เขียนทับระบบ production

โครงสร้างแนะนำ

- Data upload หรือ schedule ดึงข้อมูลแบบ read-only
- Data gate ตรวจ completeness, freshness และ unit
- AI/rule step สร้าง risk score หรือ recommendation
- Approval queue ให้ supervisor/QA review
- Dashboard + evidence export + validation sheet



เริ่มแบบ read-only ก่อนเสมอ

Exception Handling

ออกแบบกรณีผิดปกติก่อนทำ demo ที่ดูดี

ต้องเตรียมอย่างน้อย

- Missing record เช่น checklist late หรือ sensor gap
- Conflicting evidence เช่น operator note ปกติ
- แต่ temp profile ผิดปกติ
- Model uncertainty เช่น score ใกล้เคียง threshold
- Escalation failure เช่น approver ไม่อยู่กะกลางคืน
- System failure เช่น dashboard หรือ ticket system ล่ม

Happy path ไม่พอสำหรับโรงงานจริง

Missing record
late checklist / sensor gap

Conflicting evidence
operator note normal but temp abnormal

Model uncertainty
risk score ใกล้เคียง threshold

Escalation failure
ผู้อนุมัติไม่อยู่กะกลางคืน

อย่าวัดแค่ความแม่นยำของ model ให้วัดผลต่อการตัดสินใจจริง



Part 7

Business Case และ Pitch

ผู้บริหารต้องเห็นปัญหา กลไกผลลัพธ์ ความเสี่ยง
และสิ่งที่ต้องอนุมัติ



Executive Pitch: Problem → Insight → Recommendation → Impact → Ask

ทำไมเราถึงต้องการระบบที่ฉลาดขึ้น? นี่คือปัญหาที่เราพบเจอกันเป็นประจำ:

- **Data Pipelines** บางส่วน:
ระบบพังบ่อยเมื่อแหล่งข้อมูลต้นทางเปลี่ยนโครงสร้างต้องคอยซ่อมแซมแบบ Manual
- **ข้อมูลขยะ (Dirty Data) มหาศาล:** หมดเวลาไปกับการเขียน Rulesets หรือ Regex ยืดยาวเพื่อทำความสะอาดข้อมูลที่ไม่ได้มาตรฐาน
- **คอขวด (Bottleneck):**
Business ต้องการ Report หรือข้อมูลด่วน แต่ทีม Data ทำงานให้ไม่ทัน

”เรากำลังใช้คนระดับผู้เชี่ยวชาญทำงานที่ซ้ำซากเหมือนเครื่องจักร”



Solution (Example)

Google Docs Link:

<https://docs.google.com/document/d/1d64LyITDgKgSwWRmiB9WtbxiTOJdxybF/edit?usp=sharing&oid=114216695598597482325&rtpof=true&sd=true>

○ Thank You